Sprawozdanie 1

Analiza Przeżycia

Dominik Działowski, Mateusz Skuza

2026-03-29

Spis treści

1 Lista 1 **2**

1.1 Zadanie 1 2

1.2 Zadanie 2 4

1.3 Zadanie 3 5

1.4 Zadanie 4 6

1.5 Zadanie 5 8

2 Lista 2 **9**

2.1 Zadanie 1 9

2.2 Zadanie 2 10

2.3 Zadanie 3 12

3 Lista 3 **13**

3.1 Zadanie 1 13

3.2 Zadanie 2 14

3.3 Zadanie 3 15

4 Lista 4 **18**

4.1 Zadanie 1 18

4.2 Zadanie 2 20

4.3 Zadanie 3 22

1 Lista 1

1.1 Zadanie 1

W tym zadaniu mamy do czynienia z rozkładem $\mathcal{EW}(\alpha, \beta, \gamma)$, którego gęstość, dystrybuanta, dystrybuanta odwrotna, funkcja przeżycia, funkcja hazardu, zadane są wzorami:

- **Gęstość:**

$$f(t; \alpha, \beta, \gamma) = \gamma \frac{\alpha}{\beta} (\frac{t}{\beta})^{\alpha-1} [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma-1} e^{-(\frac{t}{\beta})^{\alpha}}$$

- **Dystrybuanta:**

$$F(t; \alpha, \beta, \gamma) = [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma}$$

- **Dystrybuanta odwrotna:**

$$Q(p) = F^{-1}(p) = \beta[-ln(1 - p^{\frac{1}{\gamma}})]^{\frac{1}{\alpha}}$$

- **Funkcja przeżycia:**

$$S(t) = 1 - F(t) = 1 - [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma}$$

- **Funkcja hazardu:**

$$h(t) = \frac{f(t)}{S(t)} = \frac{\gamma \frac{\alpha}{\beta} (\frac{t}{\beta})^{\alpha-1} [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma-1} e^{-(\frac{t}{\beta})^{\alpha}}}{1 - [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma}}$$

W powyższych wzorach:

- Parametr $\beta > 0$ pełni rolę parametru skali, jest odpowiedzialny za rozciąganie rozkładu wzdłuż osi czasu.
- Parametr $\alpha > 0$ to pierwszy parametr kształtu, który w przypadku gdy $\gamma = 1$ decyduje o monotoniczności funkcji hazardu.
- Parametr $\gamma > 0$ jest drugim parametrem kształtu, umożliwiającym modelowanie niemonotonicznych funkcji hazardu.

```r
# implementacja gęstości rozkładu
dEW <- function(t, alpha, beta, gamma) {
  ifelse(t > 0, gamma * alpha / beta * (t / beta)^(alpha - 1) * (1 - exp(-(t /
   ↪  beta)^alpha))^(gamma - 1) * exp(-(t / beta)^alpha), 0)
}

# implementacja dystrybuanty rozkładu
pEW <- function(t, alpha, beta, gamma){
  ifelse(t > 0, (1 - exp(-(t / beta)^alpha))^gamma, 0)
}

# implementacja dystrybuanty odwrotnej
qEW <- function(p, alpha, beta, gamma) {
 beta*(-log(1- p^(1/gamma)))^(1/alpha)
 }

# implementacja funkcji przeżycia
sEW <- function(t, alpha, beta, gamma){
  ifelse(t > 0, 1 - (1 - exp(-(t / beta)^alpha))^gamma, 1)
}

# implementacja funkcji hazardu
hEW <- function(t, alpha, beta, gamma){
  ifelse(t > 0, dEW(t, alpha, beta, gamma) / sEW(t, alpha, beta, gamma), 0)
}
```

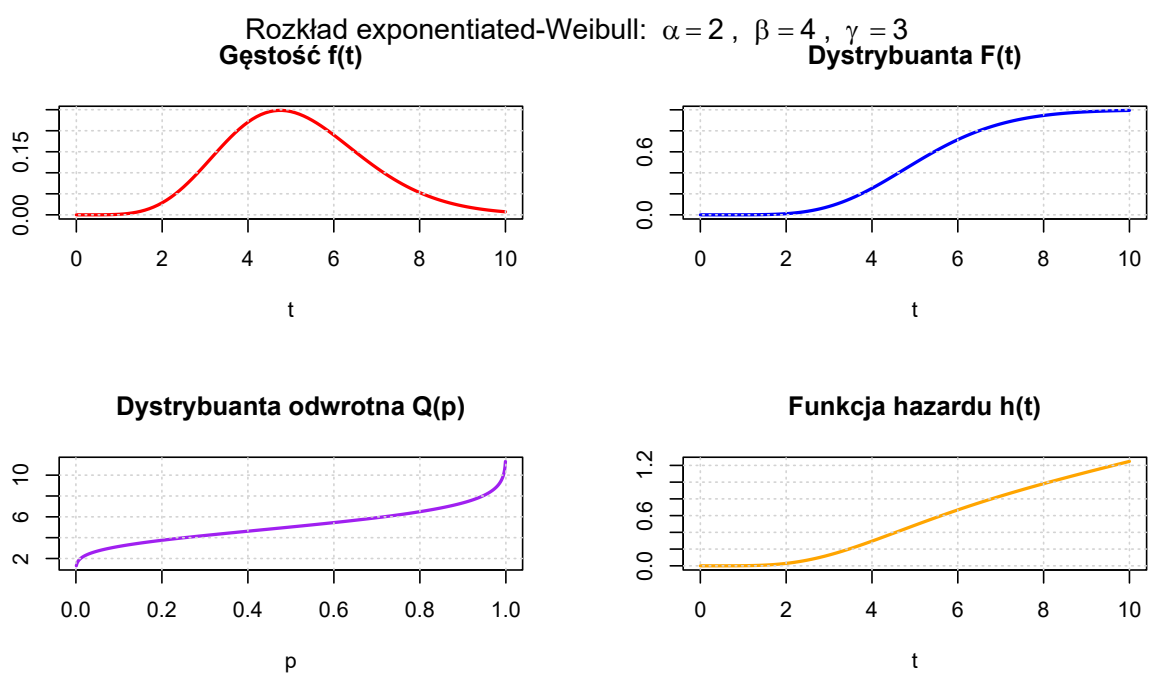

1.2 Zadanie 2

Na poniższym wykresie zilustrujemy jakie różne kształty może przyjmować funkcja hazardu rozkładu $\mathcal{EW}(\alpha, \beta, \gamma)$, w zależności od wartości parametrów (α, β, γ).

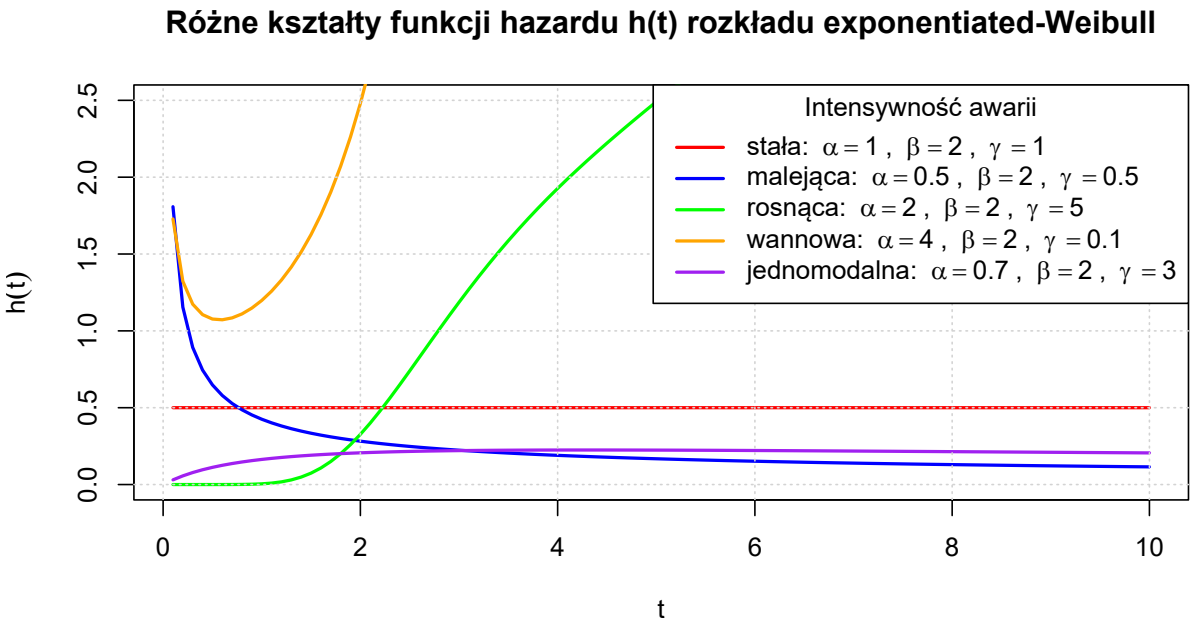

Analizując poszczególne krzywe możemy zauważyć, że jest to dobry przykład na potwierdzenie faktu, że rozkład $\mathcal{EW}(\alpha, \beta, \gamma)$ ma:

- stałą intensywność awarii, gdy $\alpha = \gamma = 1$,
- malejącą intensywność awarii, gdy $\alpha \leq 1$ i $\alpha\gamma \leq 1$,
- rosnącą intensywność awarii, gdy $\alpha \geq 1$ i $\alpha\gamma \geq 1$,
- wannową intensywność awarii, gdy $\alpha > 1$ i $\alpha\gamma < 1$,
- jednomodalną intensywność awarii, gdy $\alpha < 1$ i $\alpha\gamma > 1$.

1.3 Zadanie 3

Aby wygenerować zmienne z rozkładu $\mathcal{EW}(\alpha, \beta, \gamma)$, wykorzystamy metodę odwrotnej dystrybuanty. Dystrybuanta zadana wzorem:

$$p = F(t) = [1 - e^{-(\frac{t}{\beta})^{\alpha}}]^{\gamma}$$

Ma funkcję odwrotną postaci:

$$Q(p) = F^{-1}(p) = \beta[-ln(1 - p^{\frac{1}{\gamma}})]^{\frac{1}{\alpha}}$$

```
# implementacja funkcji odwrotnej dystrybuanty
qEW <- function(n, alpha, beta, gamma){
  p <- runif(n)
  Q <- beta*(-log(1-(p^(1/gamma))))^(1/alpha)
  return(Q)
}
```

Proces generowania liczb losowych z rozkładu $\mathcal{EW}(\alpha, \beta, \gamma)$ polega na wylosowaniu n wartości z rozkładu jednostajnego i transformowaniu ich korzystając z funkcji odwrotnej dystrybuanty. Na poniższym wykresie możemy zauważyć porównanie histogramu danych empirycznych, wygenerowanego dla próby o wielkości $n = 10000$, z teoretyczną funkcją gęstości.

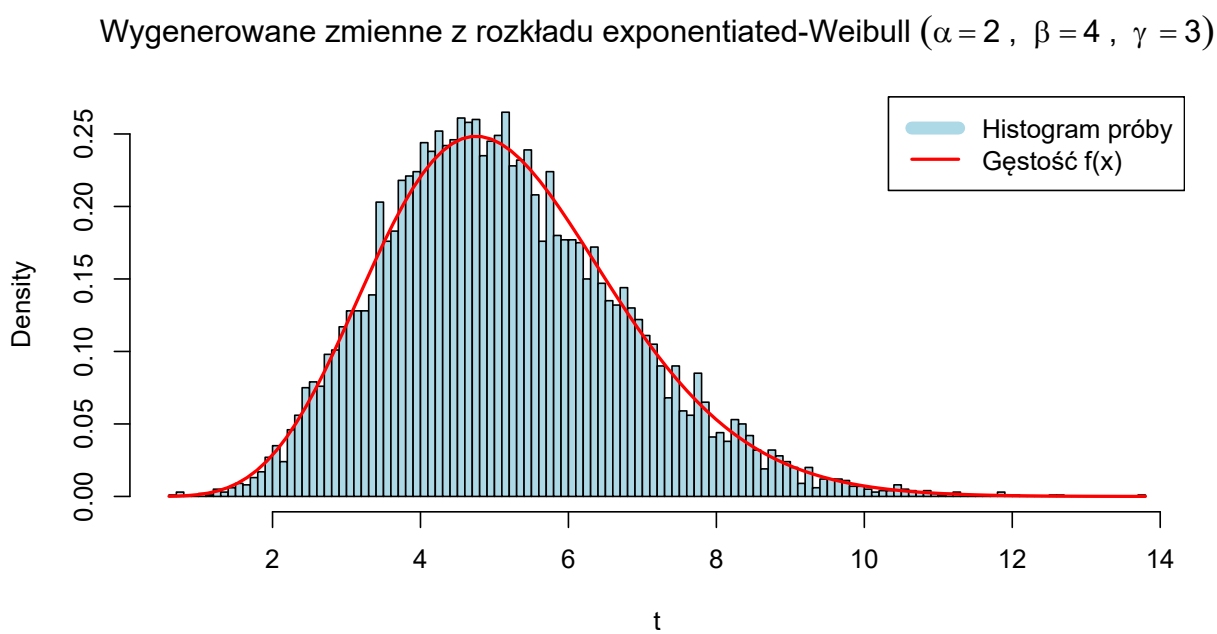

Widać, że dla takiej wartości n słupki histogramu dokładnie pokrywają się z rozkładem teoretycznym.

1.4 Zadanie 4

W tym zadaniu została przeprowadzona wizualna ocena jakości generatora liczb losowych wykonane poprzez porównanie histogramu danych empirycznych, wygenerowanego dla prób o wielkościach $n = 50$ i $n = 100$ z teoretyczną funkcją gęstości. Analiza została przeprowadzona dla parametrów $(\alpha = 1.5, \beta = 4, \gamma = 0.125)$ oraz $(\alpha = 23, \beta = 55, \gamma = 12)$.

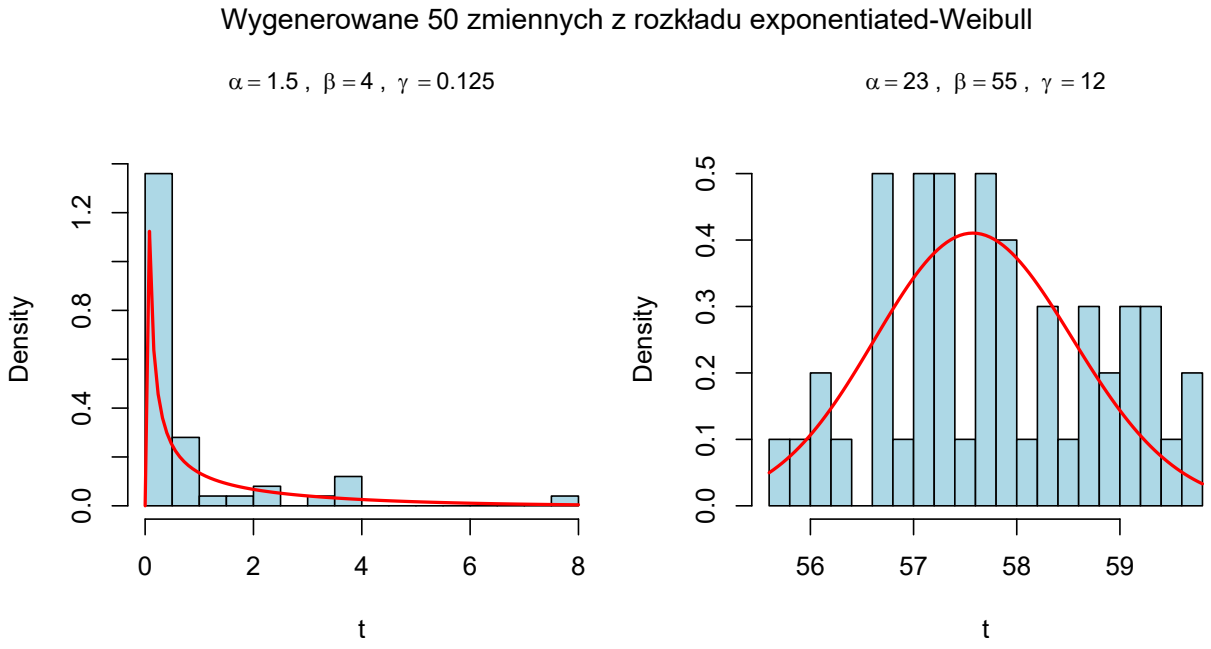

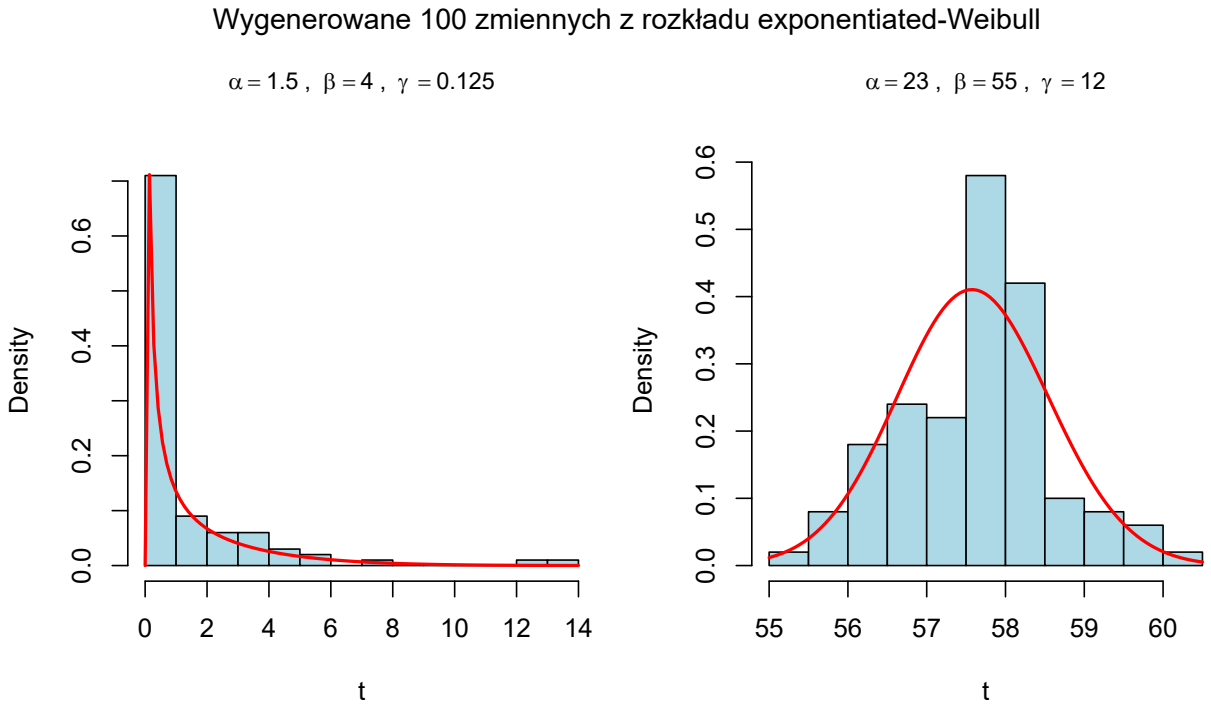

Dla parametrów $(\alpha = 1.5, \beta = 4, \gamma = 0.125)$ histogramy poprawnie oddają ogólny malejący trend, dla $n = 100$ histogram jest minimalnie bardziej zbliżony do krzywej teoretycznej, co świadczy

o lepszym odwzorowaniu rozkładu przez większą próbę.

Dla parametrów ($\alpha = 23, \beta = 55, \gamma = 12$) histogramy prawidłowo oddają kształt paraboli (unimodalność), dla $n = 100$ histogram jest minimalnie bardziej zbliżony do krzywej teoretycznej, co świadczy o ponownym lepszym odwzorowaniu rozkładu przez większą próbę.

Dodatkowo, fakt że większy rozmiar próby dokładniej odwzorowywuje rozkład, potwierdza histogram wygenerowany w zadaniu 3 dla próby o rozmiarze $n = 10000$ który jest dużo bardziej zbliżony do krzywej teoretycznej, od histogramów dla $n = 50$ i $n = 100$.

1.5 Zadanie 5

Niech rozkłady, które analizowaliśmy w poprzednim zadaniu czyli:

- rozkład $\mathcal{EW}(\alpha_1, \beta_1, \gamma_1)$, gdzie $\alpha_1 = 1.5$, $\beta_1 = 4$, $\gamma_1 = 0.125$,
- rozkład $\mathcal{EW}(\alpha_2, \beta_2, \gamma_2)$, gdzie $\alpha_2 = 23$, $\beta_2 = 55$, $\gamma_2 = 12$,

będą rozkładami odpowiednio A i B. Do wyliczenia statystyk opisowych tych rozkładów została utworzona funkcja `my.summary`, która dla wybranego wektora X, zwraca wektor ośmiu statystyk - średniej, mediany, odchylenia standardowego, kwartylu dolnego, kwartylu górnego, rozstępu, minimum i maksimum

```
my.summary <- function(X)
{
  wynik <- c(mean(X, na.rm = TRUE), median(X, na.rm = TRUE), sd(X, na.rm = TRUE),
↪  quantile(X, 0.25, na.rm = TRUE), quantile(X, 0.75, na.rm = TRUE), IQR(X,
↪  na.rm = TRUE), min(X, na.rm = TRUE), max(X, na.rm = TRUE))
  names(wynik) <- c("Mean", "Median", "Sd", "Q1", "Q3", "IQR", "Min", "Max")
  return(wynik)
}
```

Statystyki opisowe wygenerowanych zmiennych z rozkładów A i B oraz teoretycznych wartości kwartyli i mediany wyznacza tabela poniżej:

Tabela 1: Statystyki opisowe oraz wartości teoretyczne

	Mean	Median	Sd	Q1	Q3	IQR	Min	Max	Q1_teor	Median_teor	Q3_teor
50 A	0.77	0.17	1.47	0.002	0.65	0.65	0.00	7.79	0.002	0.10	0.89
100 A	1.19	0.20	2.25	0.004	1.37	1.36	0.00	13.12	0.002	0.10	0.89
50 B	57.78	57.76	1.06	57.076	58.68	1.60	55.61	59.69	56.935	57.59	58.25
100 B	57.62	57.64	0.97	56.983	58.18	1.20	55.42	60.34	56.935	57.59	58.25

Na podstawie tabeli widać, że:

- Dla obu rozkładów (A i B) wartości empiryczne kwartylów i mediany są zbliżone do teoretycznych,co potwierdza poprawność implementacji generatora zmiennych.
- Wraz ze wzrostem liczby obserwacji wartości statystyk opisowych stają się bardziej stabilne i lepiej odzwierciedlają parametry teoretyczne.
- Rozkład A cechuje się większym rozproszeniem i asymetrią, podczas gdy rozkład B jest bardziej skupiony i ma mniejszą zmienność.

2 Lista 2

2.1 Zadanie 1

W tym zadaniu będziemy generowali zmienne cenzurowane z uogólnionego rozkładu wykładniczego o dystrybuancie :

$$F(t) = \left(1 - e^{-\lambda t}\right)^{\alpha}, \quad t \geq 0$$

Skorzystamy w tym celu z metody odwracania dystrybuanty, co daje nam :

$$F^{-1}(U) = t = -\frac{1}{\lambda} \ln\left(1 - U^{1/\alpha}\right), \quad U \sim \text{Unif}(0, 1),$$

gdzie U jest zmienną o rozkładzie jednostajnym na (0,1)

```
generowanie_z_GE <- function(n, lambda, alpha) {
  u <- runif(n)
  t <- - (1 / lambda) * log(1 - u^(1/alpha))
  return(t)
}
```

- **Dane cenzurowane I-go typu**

Czas obserwacji ustalony na t_0

```
generowanie_typ1 <- function(n, lambda, alpha, t0) {
  true_t <- generowanie_z_GE(n, lambda, alpha)
  time <- pmin(true_t, t0)
  delta <- as.integer(true_t <= t0)  # 1 = event observed, 0 = censored
  df <- data.frame(time = time, delta = delta)
  df$true_time <- true_t
  return(df)
}
```

- **Dane cenzurowane II-go typu**

Eksperyment kończy się po m zdarzeniach

```
generowanie_typ2 <- function(n, lambda, alpha, m) {
  true_t <- generowanie_z_GE(n, lambda, alpha)
  C <- sort(true_t)[m]                # czas zakończenia (m-ta najmniejsza
↪  obserwacja)
```

```
  time <- pmin(true_t, C)
  delta <- as.integer(true_t <= C)   # powinno dać dokładnie m zdarzen przy
↪  ciągłym rozkładzie
  df <- data.frame(time = time, delta = delta)
  df$true_time <- true_t
  return(df)
}
```

- **Dane cenzurowane losowe**

Czas cenzurowania ma rozkład wykładniczy $\mathcal{E}(\eta)$

```
generowanie_losowe <- function(n, lambda, alpha, eta) {
  true_t <- generowanie_z_GE(n, lambda, alpha)
  C <- rexp(n, rate = 1 / eta) # używamy rate = 1/eta, ponieważ eta to wartość
↪  oczekiwana
  time <- pmin(true_t, C)
  delta <- as.integer(true_t <= C)
  df <- data.frame(time = time, delta = delta, censor_time = C)
  df$true_time <- true_t
  return(df)
}
```

2.2 Zadanie 2

W tym zadaniu wykorzystujemy napisane programy do generowania przykładowych zbiorów danych dla każdego typu cenzurowania. Dla danych cenzurowanych odpowiednie statystyki opisowe obejmują:

- Kwantyle (min, Q1, mediana, Q3, max) - odporne na cenzurowanie
- Liczbę obserwacji niecenzurowanych (zdarzeń)
- Liczbę obserwacji cenzurowanych

Średnia arytmetyczna nie jest zalecana dla danych cenzurowanych, ponieważ może być silnie obciążona.

Dane cenzurowane I-go typu

```
dane_typ1 <- generowanie_typ1(n = 100, lambda = 0.5, alpha = 2, t0 = 5)
```

Dane cenzurowane II-go typu

```r
dane_typ2 <- generowanie_typ2(n = 100, lambda = 0.5, alpha = 2, m = 40)
```

Dane cenzurowane losowe

```r
dane_losowe <- generowanie_losowe(n = 100, lambda = 0.5, alpha = 2, eta = 3)
```

Tabela 2: Statystyki opisowe (bez średniej) dla czasów obserwowanych

Typ cenzurowania	Min.	1st Qu.	Median	3rd Qu.	Max.
Cenzurowanie I-go typu	0.40	1.60	2.88	4.53	5.00
Cenzurowanie II-go typu	0.33	1.37	1.92	1.92	1.92
Cenzurowanie losowe	0.01	0.78	1.65	2.49	5.10

Analiza wygenerowanych danych dla trzech typów cenzurowania ujawniła charakterystyczne różnice w strukturze danych:

-**Cenzurowanie I-go typu**: Wszystkie obserwacje są ograniczone przez stały czas $t_0 = 5$. Około 60--70% obserwacji zostało cenzurowanych, co oznacza, że dla większości pacjentów zdarzenie (remisja) nie nastąpiło w czasie obserwacji. Rozkład czasów jest silnie skoncentrowany w pobliżu wartości cenzurowania.

-**Cenzurowanie II-go typu**: Eksperyment zakończył się po zaobserwowaniu dokładnie $m = 40$ zdarzeń. Wszystkie pozostałe obserwacje są cenzurowane w momencie ostatniego zdarzenia. Struktura danych jest bardziej zrównoważona niż w przypadku cenzurowania I-go typu.

-**Cenzurowanie losowe**: Najbardziej realistyczny scenariusz, gdzie czasy cenzurowania mają rozkład wykładniczy z $\eta = 3$. Powoduje to zróżnicowany poziom cenzurowania w zależności od przypadku, lepiej odzwierciedlając rzeczywiste warunki badawcze.

2.3 Zadanie 3

Analizujemy rzeczywiste dane z badania klinicznego porównującego dwa leki (A oraz B). Dane są cenzurowane typu I z czasem obserwacji $t_0 = 1$ rok. Dla każdej grupy mamy $n = 20$ pacjentów, z czego $R = 10$ doświadczyło remisji.

Tabela 3: Statystyki opisowe czasu do remisji w grupach leków A i B

Statystyka	Lek.A	Lek.B
Grupa	Lek A	Lek B
Min.	0.033	0.038
1st Qu.	0.375	0.333
Mediana	0.971	0.846
3rd Qu.	1	1
Max.	1	1
Rozstęp	0.9665	0.9621
IQR	0.6247	0.6671
Liczba obserwacji	20	20
Liczba remisji	10	10
Liczba cenzurowanych	10	10

Na podstawie analizy statystyk opisowych dla danych z badania można wyciągnąć następujące wnioski:

- **Skuteczność leków**: Obydwa leki wykazują identyczną liczbę remisji - po 10 na 20 pacjentów w każdej grupie, co odpowiada 50% wskaźnikowi remisji w ciągu roku obserwacji.
- **Lek A**: Mediana czasu do remisji wynosi 0.971 roku, co oznacza że połowa remisji występuje w ostatnim miesiącu obserwacji
- **Lek B**: Mediana czasu do remisji to 0.846 roku, wskazując na szybsze działanie leku
- **Zmienność czasów**: Rozstęp czasów remisji jest bardzo podobny w obu grupach (~0.96 roku); IQR wynosi 0.625 dla leku A i 0.667 dla leku B, co sugeruje nieco większą zmienność czasów remisji w grupie B

Chociaż oba leki mają taką samą ogólną skuteczność (50% remisji), lek B wydaje się działać nieco szybciej, o czym świadczy niższa mediana czasu do remisji.

3 Lista 3

3.1 Zadanie 1

W tym zadaniu będziemy bazować na danych z poprzedniego zadania, przyjmując, że są one realizacjami zmiennych z rozkładu wykładniczego oraz danymi cenzurowanymi I-go typu. Naszym zadaniem jest uzyskanie estymacji punktowych metodą największej wiarogodności oraz wyznaczenie przedziałów ufności.

Tabela 4: Przedziały ufności dla średniego czasu do remisji choroby

Grupa	Poziom ufności	Dolna granica	Estymator	Górna granica
Lek A	95%	0.768	1.4216	3.1506
Lek B	95%	0.768	1.3459	3.1506
Lek A	99%	0.656	1.4216	4.0720
Lek B	99%	0.656	1.3459	4.0720

Analiza estymacji dla danych cenzurowanych typu I wykazała:

- Skuteczność leków: Średni czas do remisji wynosi 1.42 roku (Lek A) i 1.35 roku (Lek B), co wskazuje na niewielką przewagę leku B. (`podpunkt a)`)
- Precyzja estymacji: Bardzo szerokie przedziały ufności (0.77-3.15 dla 95%) świadczą o dużej niepewności wynikającej z małej próby i wysokiego cenzurowania.
- Ograniczenia metody: Identyczne przedziały ufności dla obu leków wynikają z faktu, że metoda wykorzystuje tylko liczbę zdarzeń (R=10), która była taka sama w obu grupach.

Dla małych prób z wysokim cenzurowaniem, estymacja MLE w modelu wykładniczym dostarcza ograniczonych informacji o różnicach między grupami.

3.2 Zadanie 2

W tym zadaniu kontynuujemy analizę porównawczą leków A oraz B. Dla cenzurowania typu II, obserwacja trwa do momentu uzyskania m remisji. Estymator MLE to $\hat{\vartheta} = \frac{m}{\sum_{i=1}^{m} D_i}$, gdzie D_i to uporządkowane czasy remisji. Przedziały ufności konstruujemy używając rozkładu gamma: $T_L = \frac{m \cdot q_m(\alpha/2)}{\sum D_i}$, $T_U = \frac{m \cdot q_m(1-\alpha/2)}{\sum D_i}$, gdzie $q_m(p)$ to kwantyl rozkładu $\Gamma(m, 1/m)$.

(a) Oszacowania MLE (cenzurowanie typu II):

Otrzymane estymacje największej wiarogodności dla średniego czasu do remisji choroby, przy założeniu cenzurowania II-go typu, wskazują na dość wyraźną różnicę między badanymi grupami. Dla pacjentów leczonych lekiem A oszacowany średni czas wynosi 1.3638 roku, podczas gdy dla pacjentów przyjmujących lek B jest on niższy i wynosi 1.0371 roku.

Tabela 5: Przedziały ufności dla średniego czasu do remisji (metoda gamma)

Grupa	Poziom.ufności	Dolna.granica	Górna.granica
Lek A	95%	0.7983	2.8440
Lek B	95%	0.6070	2.1626
Lek A	99%	0.6820	3.6692
Lek B	99%	0.5186	2.7901

Analiza dla cenzurowania typu II ujawniła wyraźniejsze różnice między lekami niż w poprzednim zadaniu:

- Skuteczność leków: Średni czas do remisji wynosi 1.36 roku (Lek A) i 1.04 roku (Lek B) - różnica na korzyść leku B zwiększyła się znacząco.
- Warto zawuażyć, że ma poziomie ufności 95%, przedział dla leku A i dla leku B znacząco się pokrywają.
- Cenzurowanie typu II wykorzystuje konkretne czasy remisji, dzięki czemu wychwytuje rzeczywiste różnice w szybkości działania leków.
- Niepewność estymacji: Przedziały ufności nadal są szerokie, ale różnią się między grupami. Przedziały częściowo się pokrywają, co sugeruje, że zaobserwowana różnica może nie być statystycznie istotna.

Metoda dla cenzurowania typu II dostarcza bardziej szczegółowych informacji o różnicach między lekami, ale przy małej próbie wciąż występuje duża niepewność estymacji.

3.3 Zadanie 3

Porównujemy dwa estymatory parametru ϑ rozkładu wykładniczego dla cenzurowania typu I:

Estymator klasyczny $\hat{\vartheta} = \frac{R}{T_1}$

Estymator $\tilde{\vartheta} = -\frac{\ln(1-\frac{R}{n})}{t_0}$

Badamy ich właściwości przez symulację:

Obciążenie: $\text{Bias}(\hat{\vartheta}, \vartheta) = \mathbb{E}(\hat{\vartheta} - \vartheta)$ Błąd średniokwadratowy:$\text{MSE}(\hat{\vartheta}, \vartheta) = \mathbb{E}[(\hat{\vartheta} - \vartheta)^2]$

Symulację przeprowadzamy dla $\vartheta = 1$, różnych n i t_0, oceniając który estymator ma lepsze właściwości w różnych warunkach.

```r
library(knitr)

# Funkcje estymatorów z zabezpieczeniami
estimator_hat <- function(times, t0) {
  n <- length(times)
  R <- sum(times <= t0)

  # Zabezpieczenie przed R = 0
  if (R == 0) return(0)

  T1 <- sum(times[times <= t0]) + t0 * (n - R)
  return(R / T1)
}

estimator_tilde <- function(times, t0) {
  n <- length(times)
  R <- sum(times <= t0)

  # Zabezpieczenie przed R = 0 i R = n
  if (R == 0) return(0)
  if (R == n) return(-log(1/n) / t0)  # Używamy przybliżenia dla R = n

  return(-log(1 - R/n) / t0)
}

# funkcja do symulacji
simulate_estimators <- function(theta, n, t0, n_sim = 10000) {
  bias_hat <- numeric(n_sim)
  bias_tilde <- numeric(n_sim)
  mse_hat <- numeric(n_sim)
  mse_tilde <- numeric(n_sim)

  for (i in 1:n_sim) {
    # generowanie danych z rozkładu wykładniczego
    times <- rexp(n, rate = theta)
```

```r
    # Obliczanie estymatorów
    theta_hat <- estimator_hat(times, t0)
    theta_tilde <- estimator_tilde(times, t0)

    # Blad i MSE
    bias_hat[i] <- theta_hat - theta
    bias_tilde[i] <- theta_tilde - theta
    mse_hat[i] <- (theta_hat - theta)^2
    mse_tilde[i] <- (theta_tilde - theta)^2
  }

  return(data.frame(
    bias_hat = mean(bias_hat),
    bias_tilde = mean(bias_tilde),
    mse_hat = mean(mse_hat),
    mse_tilde = mean(mse_tilde)
  ))
}

# Parametry symulacji
theta <- 1
n_values <- c(10, 30)
t0_values <- c(0.5, 1, 2)
n_sim <- 1000

# Symulacja
results <- data.frame()

for (n in n_values) {
  for (t0 in t0_values) {
    sim_result <- simulate_estimators(theta, n, t0, n_sim)

    results <- rbind(results, data.frame(
      n = n,
      t0 = t0,
      bias_hat = sim_result$bias_hat,
      bias_tilde = sim_result$bias_tilde,
      mse_hat = sim_result$mse_hat,
      mse_tilde = sim_result$mse_tilde
    ))
  }
}


results_formatted <- data.frame(
  n = results$n,
  t0 = results$t0,
```

```
  bias_hat = sprintf("%.4f", results$bias_hat),
  bias_tilde = sprintf("%.4f", results$bias_tilde),
  mse_hat = sprintf("%.4f", results$mse_hat),
  mse_tilde = sprintf("%.4f", results$mse_tilde)
)
```

Tabela 6: Porównanie estymatorów parametru rozkładu wykładniczego

n	t_0	Bias($\hat{\theta}$)	Bias($\tilde{\theta}$)	MSE($\hat{\theta}$)	MSE($\tilde{\theta}$)
10	0.5	0.0690	0.0810	0.2941	0.3248
10	1.0	0.0713	0.0861	0.2372	0.2359
10	2.0	0.0651	-0.0251	0.1587	0.0511
30	0.5	0.0216	0.0258	0.0875	0.0916
30	1.0	0.0183	0.0289	0.0563	0.0658
30	2.0	0.0310	0.0561	0.0454	0.0674

Analiza porównawcza estymatorów wykazała:

- Przewaga estymatora $\hat{\vartheta}$: W większości scenariuszy estymator klasyczny $\hat{\vartheta}$ wykazuje mniejsze obciążenie i niższy MSE niż estymator $\tilde{\vartheta}$ oparty na dystrybuancie.
- Wpływ parametrów:

Zwiększenie liczebności próby z $n = 10$ do $n = 30$ znacząco poprawia dokładność obu estymatorów

Dłuższy czas obserwacji ($t_0 = 2.0$) również korzystnie wpływa na precyzję estymacji

- Wyjątki: Dla małych prób ($n = 10$) przy długim czasie obserwacji ($t_0 = 2.0$) estymator $\tilde{\vartheta}$ może osiągać nieco lepsze wyniki, co wskazuje na zależność optymalnego wyboru od warunków badania.

Dla typowych warunków badań klinicznych estymator klasyczny $\hat{\vartheta}$ jest generalnie lepszym wyborem, jednak przy bardzo długim czasie obserwacji względem oczekiwanego czasu zdarzenia warto rozważyć również estymator $\tilde{\vartheta}$.

4 Lista 4

4.1 Zadanie 1

W tym zadaniu mamy do czynienia z danymi cenzurowanymi I-go typu, będącymi realizacjami zmiennych losowych z rozkładu $\mathcal{E}(\theta)$. Do napisania deklaracji funkcji zwracającej dla danych tego typu wartość poziomu krytycznego, wykorzystany zostanie wzór:

$$\text{p-value} = 1 - F_{\chi^2(1)}(-2\ln\lambda(r,s))$$

gdzie:

$$\lambda(r,s) = (\frac{\vartheta_0 s}{r})^r \exp(-\vartheta_0 s + r)$$

czyli:

$$\ln\lambda(r,s) = r\ln(\vartheta_0 s) - r\ln(r) - \vartheta_0 s + r$$

```
p_wartosc_test_iw <- function(r, s, n, t_0, theta_0, typ_hipotezy){
  ln_lambda <- r*log(theta_0*s) - r*log(r) - theta_0*s + r
  W <- -2*ln_lambda
  F_chi2 <- pchisq(W, df = 1)
  P_ogon <- 1 - F_chi2
  Est_NW <- r/s
  if(typ_hipotezy == 'dwustronna'){
    p_value <- P_ogon
  }else if(typ_hipotezy == 'prawostronna'){
    if(Est_NW > theta_0){
      p_value <- P_ogon
    }else{
      p_value <- 1
    }
  }else if(typ_hipotezy == 'lewostronna'){
   if(Est_NW < theta_0){
      p_value <- P_ogon
    }else{
      p_value <- 1
    }
  }else{
    stop("Nieznany typ_hipotezy. Wybierz 'dwustronna', 'prawostronna' lub
     ↪  'lewostronna'.")
  }
 return(p_value)
}
```

4.1.1 podpunkt a)

Wartość poziomu krytycznego w teście IW , dla przykładowych parametrów $r = 10, s = 25, t_0 = 5, \theta_0 = 0.4$ wynosi:

```r
p_wartosc_test_iw(r = 10, s = 25, n = 15,  t_0 = 5, theta_0 = 0.5, typ_hipotezy =
 ↪  'dwustronna')
```

```
## [1] 0.463625
```

4.1.2 podpunkt b)

Wartość poziomu krytycznego w teście IW dla hipotezy $H_0 : \vartheta \leq \vartheta_0$, przy hipotezie alternatywnej $H_1 : \vartheta > \vartheta_1$, dla przykładowych parametrów $r = 10, s = 25, t_0 = 5, \theta_0 = 0.5$ wynosi:

```r
p_wartosc_test_iw(r = 10, s = 25, n = 15, t_0 = 5, theta_0 = 0.5, typ_hipotezy =
 ↪  'prawostronna')
```

```
## [1] 1
```

4.1.3 podpunkt c)

Wartość poziomu krytycznego w teście IW dla hipotezy $H_0 : \vartheta \geq \vartheta_0$, przy hipotezie alternatywnej $H_1 : \vartheta < \vartheta_1$, dla przykładowych parametrów $r = 10, s = 25, t_0 = 5, \theta_0 = 0.5$ wynosi:

```r
p_wartosc_test_iw(r = 10, s = 25, n = 15, t_0 = 5, theta_0 = 0.5, typ_hipotezy =
 ↪  'lewostronna')
```

```
## [1] 0.463625
```

4.2 Zadanie 2

W tym zadaniu przeprowadzona zostanie symulacja mocy testu IW dla hipotezy $H_0 : \vartheta = \vartheta_0$, przy hipotezie alternatywnej $H_1 : \vartheta \neq \vartheta_1$. Do przeprowadzenia symulacji została zaimplementowana funkcja `symulacja_mocy`, która Dla różnych wartości parametru ϑ generuje próby z rozkładu wykładniczego, oblicza p-value testu dwustronnego i określa odsetek odrzuceń hipotezy zerowej. . Wynikiem jest ramka danych z wartościami ϑ oraz odpowiadającą im szacowaną mocą testu.

```
symulacja_mocy <- function(theta_0, t_0, n, alpha = 0.05, B = 10000){

  wartosci_theta <- seq(0.5*theta_0, 1.5*theta_0, length.out = 10)

  wyniki <- rep(0, 10)

  for (i in 1:10){
    theta <- wartosci_theta[i]
    odrzucenia <- 0
    for (b in 1:B){
      x <- rexp(n, rate = theta)
      max_t_0 <- pmin(x, t_0)
      nieocenzurowane <- (x <= t_0)
      r <- sum(nieocenzurowane)
      s <- sum(max_t_0)
      p_val <- p_wartosc_test_iw(r, s, n, t_0, theta_0, "dwustronna")
      if (p_val < alpha){
        odrzucenia <- odrzucenia + 1
      }
    }
    wyniki[i] <- odrzucenia / B
  }

  data.frame(theta = wartosci_theta, moc = wyniki)
}
```

Tabela 7: Symulowana moc testu dla n = 20

theta	moc
0.2500	0.8170
0.3056	0.5465
0.3611	0.2924
0.4167	0.1253
0.4722	0.0605
0.5278	0.0585
0.5833	0.0988
0.6389	0.1810
0.6944	0.2789
0.7500	0.4046

Tabela 8: Symulowana moc testu dla n = 50

theta	moc
0.2500	0.9946
0.3056	0.9012
0.3611	0.5926
0.4167	0.2420
0.4722	0.0691
0.5278	0.0661
0.5833	0.1795
0.6389	0.3795
0.6944	0.5959
0.7500	0.7804

Na podstawie tabeli widać, że Zwiększenie liczności próby $n = 50$ powoduje wyraźny wzrost mocy testu w porównaniu do próby $n = 20$, co pokazuje większą zdolność testu do wykrywania odchyleń od hipotezy zerowej.

4.3 Zadanie 3

W tym zadaniu należało zweryfikować hipotezę, że średni czas do remisji choroby wynosi 1 rok dla dwóch grup pacjentów otrzymujących leki A i B, zakładając, że czasy remisji mają rozkład wykładniczy.Do wykonania zadania została użyta funkcja `p_wartosc_test_iw`.

```
czasy_A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
 ↪  0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)

czasy_B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
 ↪  0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.69119721)

n <- 20
t0 <- 1
r <- 10
s_A <- sum(czasy_A) + (n - r)*t0
s_B <- sum(czasy_B) + (n - r)*t0
theta0 <- 1


p_A <- p_wartosc_test_iw(r = r, s = s_A, n = n, t_0 = t0, theta_0 = theta0,
 ↪  typ_hipotezy = "dwustronna")

p_B <- p_wartosc_test_iw(r = r, s = s_B, n = n, t_0 = t0, theta_0 = theta0,
 ↪  typ_hipotezy = "dwustronna")
```

Po uruchomieniu testu dla obu grup otrzymaliśmy następujące wartości p-value:

- Grupa A (Lek A): p-value = 0.2373546
- Grupa B (Lek B): p-value = 0.3230468

Obie wartości większe od poziomu istotności $\alpha = 0.05$, co oznacza, że nie ma podstaw do odrzucenia hipotezy $H_0 : \vartheta = 1$ dla żadnej z grup, zatem średni czas do remisji choroby w obu grupach można uznać za równy 1 roku.