Sprawozdanie 2

Analiza Przeżycia

Dominik Działowski, Mateusz Skuza

2026-03-29

Spis treści

1 Lista 5 **2**

1.1 Zadanie 1 2

1.2 Zadanie 2 5

1.3 Zadanie 3 7

2 Lista 6 **11**

2.1 Zadanie 1 11

2.2 Zadanie 2 15

3 Lista 7 **16**

3.1 Zadanie 1 16

3.2 Zadanie 2 18

4 Lista 8 **20**

4.1 Zadanie 1 20

4.2 Zadanie 2 23

1 Lista 5

1.1 Zadanie 1

W tym zadaniu na podstawie danych opisanych zadaniu 3 z listy 2, mamy narysować wykresy estymatorów.

1.1.1 podpunkt a)

Najpierw narysujemy wykres estymatora Kaplana-Meiera, który jest postaci

$$\hat{S}(t) = \prod_{i:t(i)\leq t} \frac{r_i - di}{r_i}, \quad \text{gdy } 0 \leq t \leq t^+ \ ,$$

gdzie

$$r_i = \sum_{j=1}^{n} \mathbb{1}_{[t(i),\infty)}(x_j)$$

oraz

$$d_i = \sum_{j=1}^{n} \mathbb{1}_{\{t(i)\}}(t_j)\mathbb{1}_{\{1\}}(\delta_j).$$

```r
library(survival)
library(survminer)

remisja_A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
               0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)

remisja_B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
               0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.69119721)

dane_A <- data.frame(
  time = c(remisja_A, rep(1, 10)),
  delta = c(rep(1,10), rep(0,10)),
  grupa = "Lek A"
)

dane_B <- data.frame(
  time = c(remisja_B, rep(1, 10)),
  delta = c(rep(1,10), rep(0,10)),
  grupa = "Lek B"
)

dane <- rbind(dane_A, dane_B)
```

```r
fit_KM <- survfit(Surv(time, delta) ~ grupa, data = dane, type = "kaplan-meier")

ggsurvplot(
  fit_KM,
  data = dane,
  conf.int = FALSE,
  legend.title = "Grupa",
  legend.labs = c("Lek A", "Lek B"),
  xlab = "Czas",
  ylab = "S(t)",
  ggtheme = theme_minimal()
)
```

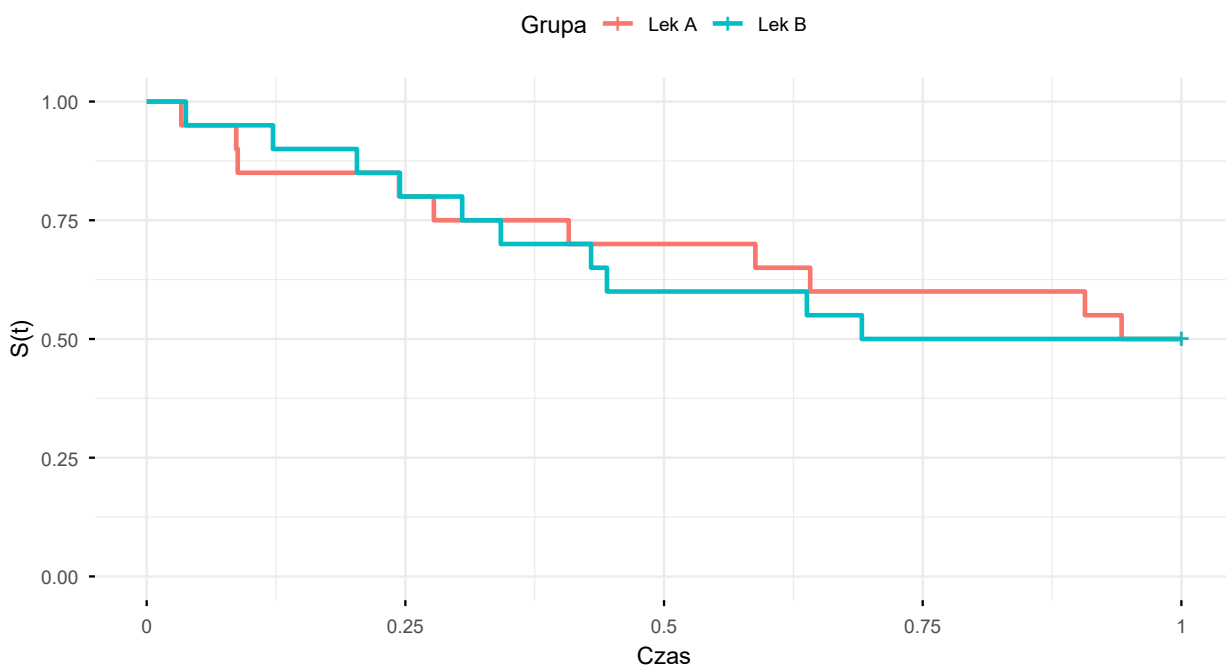

1.1.2 podpunkt b)

Teraz zajmiemy się estymatorem Fleminga-Harringtona, który jest postaci

$$\tilde{S}(t) = \exp\left(-\sum_{j:t_{(j)}\leq t} \frac{d_j}{r_j}\right) \quad \text{gdy } 0 \leq t \leq t_{(n)} \ ,$$

gdzie r_j i d_j są zdefiniowane tak samo jak w przypadku estymatora Kaplana-Meiera.

```
fit_FH <- survfit(Surv(time, delta) ~ grupa, data = dane, type =
 ↪  "fleming-harrington")

ggsurvplot(
  fit_FH,
  data = dane,
  conf.int = FALSE,
  legend.title = "Grupa",
  legend.labs = c("Lek A", "Lek B"),
  xlab = "Czas",
  ylab = "S(t)",
  ggtheme = theme_minimal()
)
```

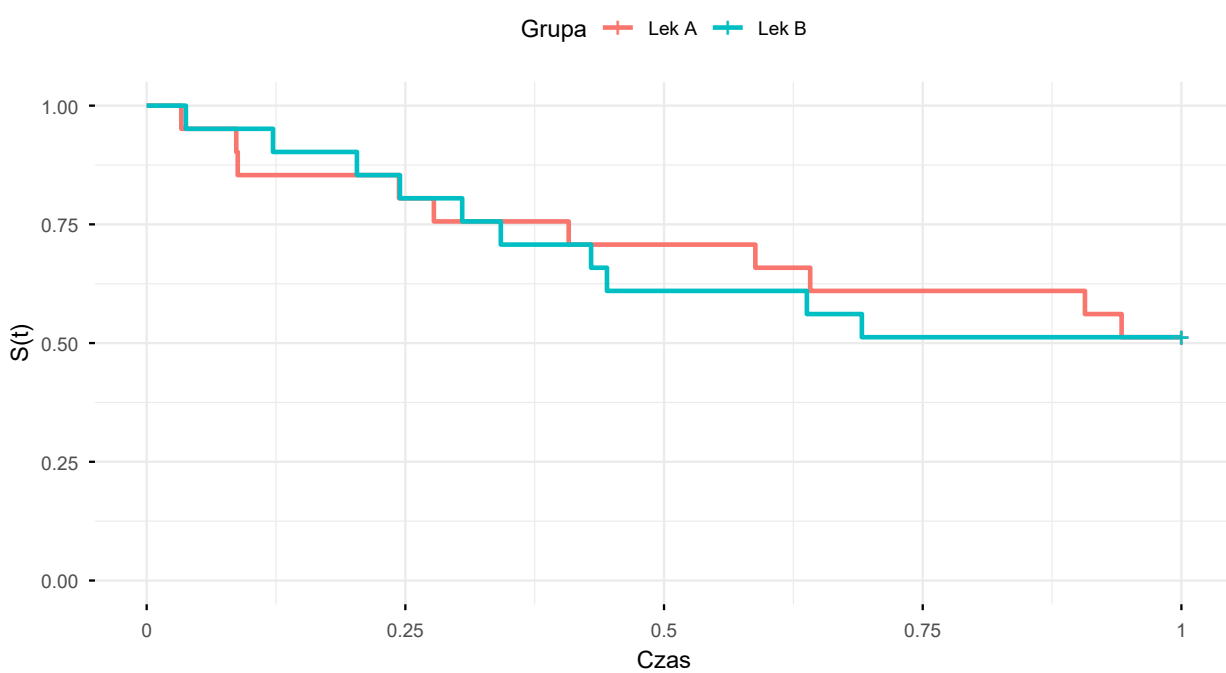

Na podstawie powyższych wykresów możemy stwierdzić, że nie ma znaczących różnic w działaniu leków A i B. Na wykresach obu estymatorów widzimy, że ich krzywe są bardzo podobne.

1.2 Zadanie 2

W tym zadaniu stworzymy progoram do generowania wykresu estymatora Kaplana-Meiera z "ogonem" estymowanym zgodnie z propozycją Browna, Hollandera i Kowara. Zaproponowali oni estymator postaci :

$$\hat{S}(t) = \exp\left[\frac{ln\hat{S}(t^+)}{t^+}t\right], \quad \text{dla } t > t^+.$$

```
library(survival)
library(ggplot2)

remisja_A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
               0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)

remisja_B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
               0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.69119721)


daneA <- data.frame(time = c(remisja_A, rep(1, 10)),
                    delta = c(rep(1, 10), rep(0, 10)))

daneB <- data.frame(time = c(remisja_B, rep(1, 10)),
                    delta = c(rep(1, 10), rep(0, 10)))


KM_ogon <- function(time, delta, t_x = 2) {

  fit <- survfit(Surv(time, delta) ~ 1)

  t_plus <- max(time)
  S_tplus <- tail(fit$surv, 1)

  t_ogon <- seq(t_plus, t_x, length.out = 200)
  S_ogon <- exp((log(S_tplus)/t_plus) * t_ogon)

  df1 <- data.frame(time = fit$time, surv = fit$surv)
  df1 <- df1[df1$time <= t_plus, ]
  df2 <- data.frame(time = t_ogon, surv = S_ogon)

  rbind(df1, df2)
}

kmA <- KM_ogon(daneA$time, daneA$delta)
kmB <- KM_ogon(daneB$time, daneB$delta)
```

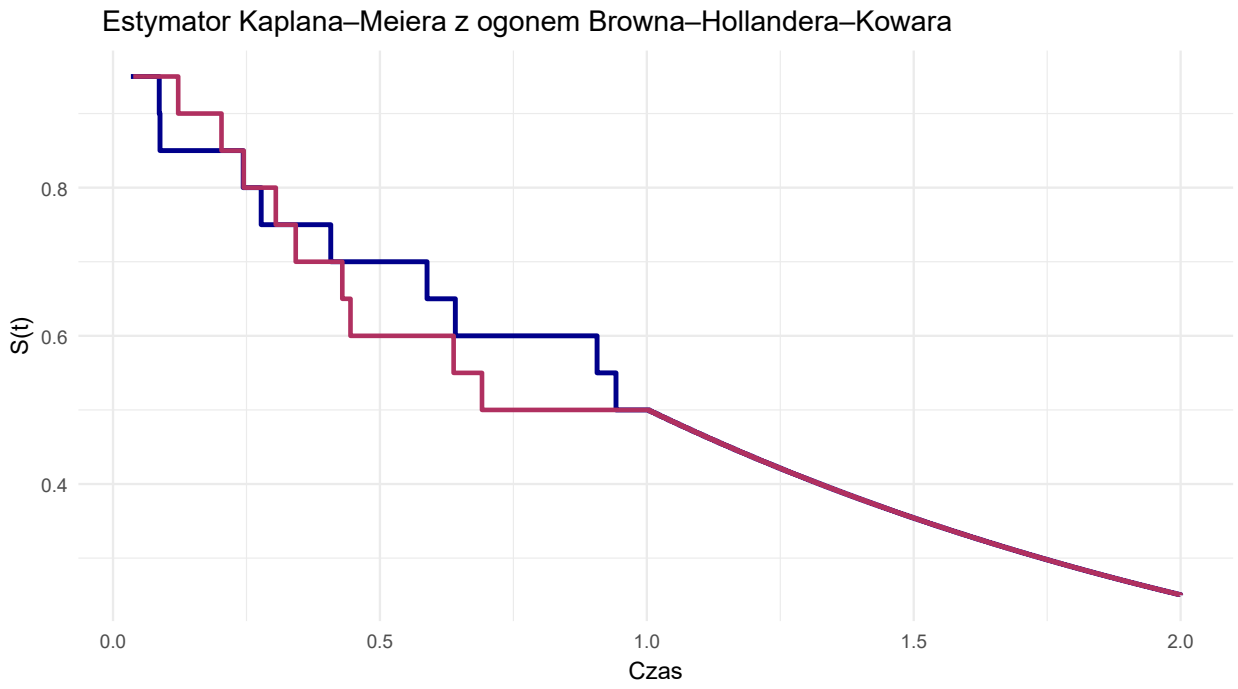

Rysunek przedstawia szacowanie funkcji przeżycia czasu do remisji choroby w dwóch grupach pacjentów. Wykres jest podzielony na część stanowiącą standardowy estymator Kaplana-Meiera oraz tę stanowiącą „ogon” uzyskany metodą Browna, Hollandera i Kowara. Lek A początkowo wykazuje szybszą remisję, lecz przez większość czasu obserwacji utrzymuje wyższe wartości funkcji przeżycia niż Lek B.

1.3 Zadanie 3

W tym zadaniu skorzystamy z funkcji `generowanie_typ1` z wcześniejszej listy, aby wygenerować $M = 1000$ zbiorów danych cenzurowanych I-go typu z uogólnionego rozkładu wykładniczego ($\mathcal{GE}(\lambda, \alpha)$). Na podstawie wygenerowanych zbiorów danych wyznaczymy oszacowania wartości funkcji przeżycia w punktach t_0 i $2t_0$, korzystając z estymatora Kaplana-Meiera z "ogonem" estymowanym zgodnie z propozycją Browna, Hollandera i Kowara.

```r
generowanie_z_GE <- function(n, lambda, alpha) {
  u <- runif(n)
  t <- - (1 / lambda) * log(1 - u^(1/alpha))
  return(t)
}
generowanie_typ1 <- function(n, lambda, alpha, t0) {
  true_t <- generowanie_z_GE(n, lambda, alpha)
  time <- pmin(true_t, t0)
  delta <- as.integer(true_t <= t0)
  df <- data.frame(time = time, delta = delta)
  df$true_time <- true_t
  return(df)
}
```

```r
library(survival)
library(ggplot2)

KM_BHK <- function(time, delta) {
  fit <- survfit(Surv(time, delta) ~ 1)
  t_plus <- max(time[delta == 1])
  S_tplus <- summary(fit, times = t_plus)$surv
  theta <- -log(S_tplus) / t_plus
  list(fit = fit, theta = theta, t_plus = t_plus, S_tplus = S_tplus)
}


S_BHK <- function(km, t) {
  fit <- km$fit
  t_plus <- km$t_plus
  theta <- km$theta

  if (t <= t_plus) {
    return(summary(fit, times = t)$surv)
  } else {
    return(exp(-theta * t))
  }
}
```

```r
M <- 1000
lambda <- 1
alpha <- 2
n_values <- c(30, 50, 100)

#wartosc oczekiwana
t0 <- (1/lambda) * gamma(1 + 1/alpha)

results <- list()

for (n in n_values) {
  S_t0 <- numeric(M)
  S_2t0 <- numeric(M)

  for (m in 1:M) {
    dane <- generowanie_typ1(n, lambda, alpha, t0)
    km_bhk <- KM_BHK(dane$time, dane$delta)

    S_t0[m] <- S_BHK(km_bhk, t0)
    S_2t0[m] <- S_BHK(km_bhk, 2*t0)
  }

  results[[paste0("n", n, "_t0")]] <- S_t0
  results[[paste0("n", n, "_2t0")]] <- S_2t0
}
```

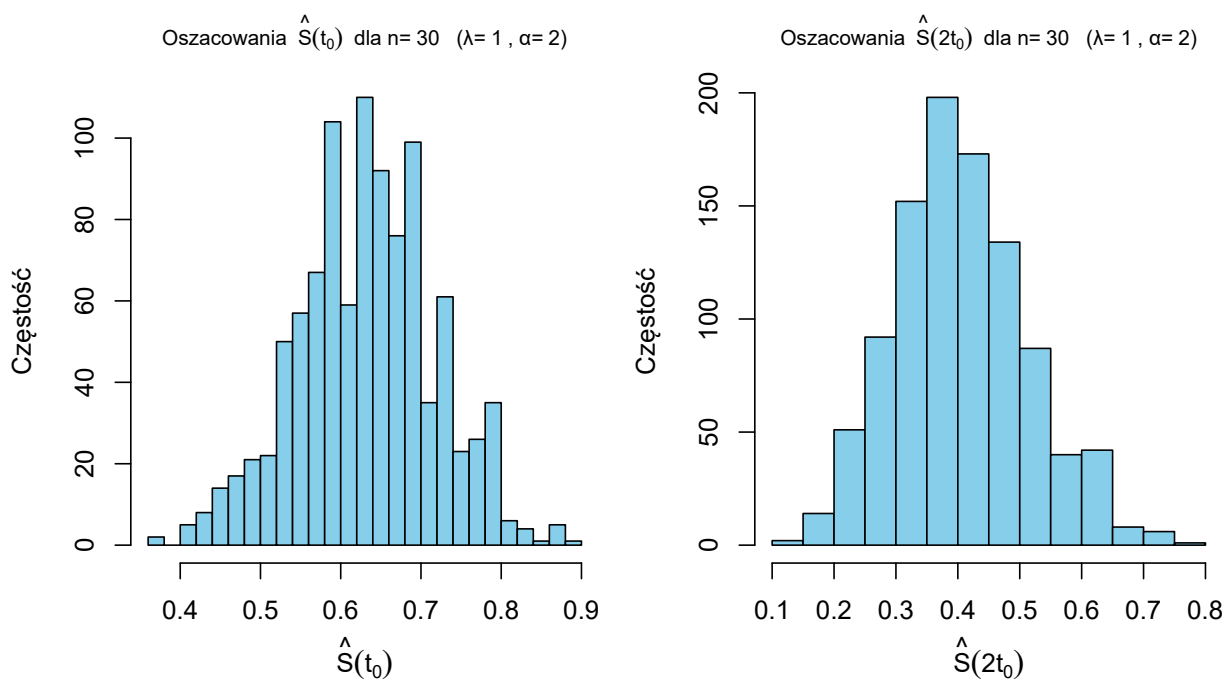

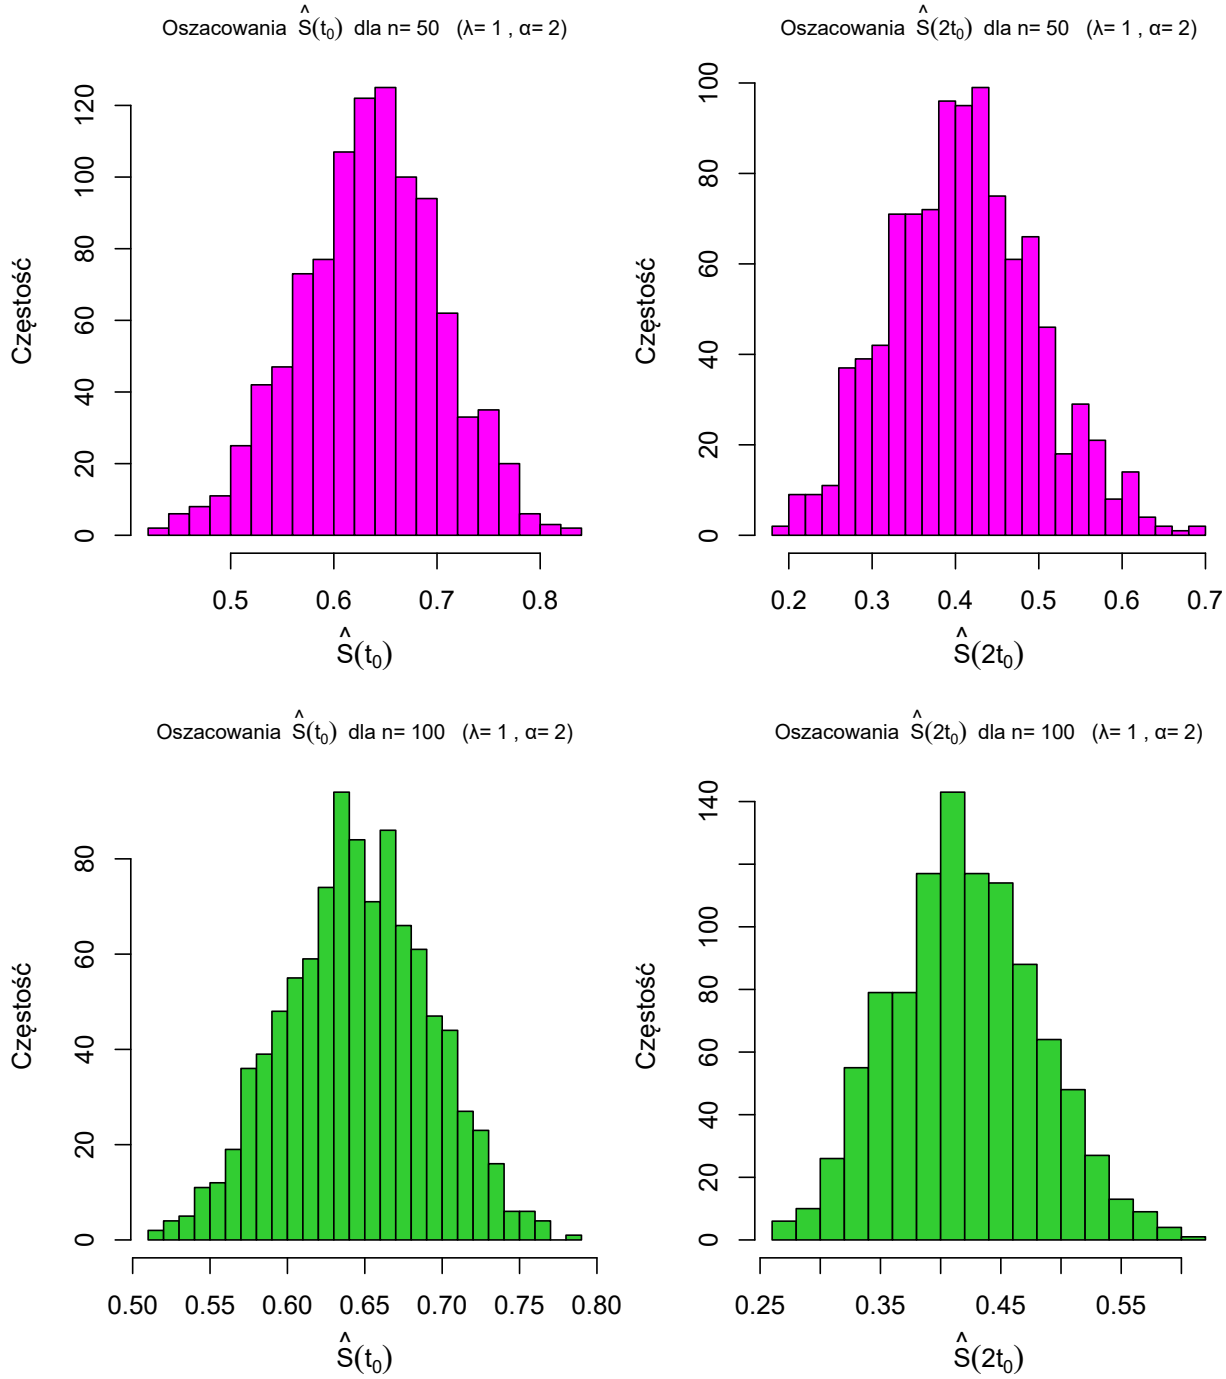
Oszacowania Ŝ(t0) dla n= 50 (λ= 1 , α= 2)
Częstość
Ŝ(t0)
Oszacowania Ŝ(2t0) dla n= 50 (λ= 1 , α= 2)
Częstość
Ŝ(2t0)
Oszacowania Ŝ(t0) dla n= 100 (λ= 1 , α= 2)
Częstość
Ŝ(t0)
Oszacowania Ŝ(2t0) dla n= 100 (λ= 1 , α= 2)
Częstość
Ŝ(2t0)

Wnioski:

- Dla małych prób (n = 30) rozkłady oszacowań $\hat{S}(t_0)$ i szczególnie $\hat{S}(2t_0)$ są szerokie, lekko skośne i mniej regularne. Przy większych próbach (n = 50), a zwłaszcza n = 100, histogramy wyraźnie stają się węższe, bardziej symetryczne i przypominają kształt dzwonowy, co wskazuje na zmniejszenie wariancji oraz stabilizowanie się estymatora.
- Wartości $\hat{S}(t_0))$ są bardziej skupione i mają mniejszą wariancję, ponieważ $t_0$leży w obszarze obserwacji. Natomiast w punkcie $2t_0$, który znajduje się poza zakresem obserwacji i wymaga użycia ogona BHK, histogramy są bardziej rozproszone.
- Na podstawie histogramów można przypuszczać, że estymator Kaplana-Meiera z ogonem BHK jest asymptotycznie normalny zarówno w t_0 jak i $2t_0$. Dla n = 100 rozkłady są już bliskie normalności: w miarę symetryczne, z wyraźnym skupieniem wokół wartości średniej. Dla małych prób normalność nie jest widoczna, szczególnie w $2t_0$, jednak zwiększanie n powoduje regularne upodobnianie się rozkładu do normalnego.

2 Lista 6

2.1 Zadanie 1

2.1.1 podpunkt a)

W tym zadaniu mamy do czynienia z estymatorem Kaplana-Meiera, czyli estymatorem:

$$\hat{S}(t) = \prod_{i:t(i)\leq t} \frac{r_i - di}{r_i}, \quad \text{gdy } 0 \leq t \leq t^+,$$

gdzie

$$r_i = \sum_{j=1}^{n} \mathbb{1}_{[t(i),\infty)}(x_j)$$

oraz

$$d_i = \sum_{j=1}^{n} \mathbb{1}_{\{t(i)\}}(t_j)\mathbb{1}_{\{1\}}(\delta_j).$$

Estymator średniego czasu życia w oparciu o estymator Kaplana-Meiera $\hat{S}(t)$, można uzyskać ze wzoru:

$$\hat{\mu} = \int_0^\infty \hat{S}(t)\ dt.$$

W celu oszacowania ogona, zostanie wykorzystana opcja zaproponowana przez Browna, Hollandera i Kowara, której estymator wynosi:

$$\hat{S}(t) = \exp\left(\frac{ln\hat{S}(t^+)}{t^+}t\right), \quad \text{dla } t > t^+.$$

Wówczas cały wzór będzie wyglądał następująco:

$$\hat{\mu} = \int_0^{t^+} \hat{S}(t)\ dt\ + \int_{t^+}^\infty \exp\left(\frac{ln\hat{S}(t^+)}{t^+}t\right)\ dt = I_1 + I_2.$$

gdzie całka I_1 jest obliczana poprzez sumowanie pól prostokątów (funkcja Estymatora Kaplana--Meiera jest schodkowa), natomiast:

$$I_2 = \int_{t^+}^\infty \exp(-\vartheta t)\ dt = \frac{1}{\vartheta}\exp(-\vartheta t^+).$$

Na podstawie tego wzoru zostanie zaimplementowana funkcja `estymacja_sr_czasu_zycia_km` estymująca średni czas życia w oparciu o ten estymator.

```r
library(survival)
library(dplyr)

estymacja_sr_czasu_zycia_km <- function(T, E) {

  dane_km <- data.frame(time = T, status = E)
  km_fit <- survfit(Surv(time, status) ~ 1, data = dane_km, type =
↪  "kaplan-meier")
  wyniki_km <- data.frame(time = km_fit$time, surv = km_fit$surv)

  punkt_startowy <- data.frame(time = 0, surv = 1)

  dane_km_uzupelnione <- bind_rows(punkt_startowy, wyniki_km) %>%
    arrange(time) %>%
    distinct(time, .keep_all = TRUE)

  czasy <- dane_km_uzupelnione$time
  S_t   <- dane_km_uzupelnione$surv

  a <- S_t[-length(S_t)]
  b <- diff(czasy)
  I_1 <- sum(a * b)

  t_plus <- max(km_fit$time)
  S_t_plus <- S_t[length(S_t)]

  czy_cenzurowana <- (km_fit$n.event[length(km_fit$n.event)] == 0)

  if (!czy_cenzurowana || S_t_plus <= 0) {
    I_2 <- 0
  } else {
    theta <- -log(S_t_plus)/t_plus
    I_2 <- S_t_plus/theta
  }

  sredni_czas_zycia <- I_1 + I_2
  return(sredni_czas_zycia)
}
```

2.1.2 podpunkt b)

Do tego zadania wykorzystamy estymator Fleminga-Harringtona, który jest określony wzorem:

$$\tilde{S}(t) = \exp\left(-\sum_{j:t_{(j)}\leq t} \frac{d_j}{r_j}\right) \quad \text{gdy } 0 \leq t \leq t_{(n)}$$

gdzie r_j i d_j są zdefiniowane analogicznie jak dla estymatora Kaplana-Meiera.

W celu oszacowania ogona funkcji, ponownie zostanie wykorzystana opcja zaproponowana przez Browna, Hollandera i Kowara. Wówczas całkowity estymator średniego czasu życia przyjmie postać:

$$\hat{\mu} = \int_0^{t^+} \tilde{S}(t)\ dt\ + \int_{t^+}^{\infty} \exp\left(\frac{\ln \tilde{S}(t^+)}{t^+} t\right)\ dt = I_1 + I_2.$$

gdzie całka I_1 jest obliczana poprzez sumowanie pól prostokątów (funkcja Estymatora Fleminga--Harringtona jest schodkowa), natomiast:

$$I_2 = \int_{t^+}^{\infty} \exp(-\vartheta t)\ dt = \frac{1}{\vartheta}\exp(-\vartheta t^+).$$

Na podstawie tego wzoru zostanie zaimplementowana funkcja `estymacja_sr_czasu_zycia_fh` estymująca średni czas życia w oparciu o ten estymator.

```
estymacja_sr_czasu_zycia_fh <- function(T, E) {

  dane_fh <- data.frame(time = T, status = E)
  fh_fit <- survfit(Surv(time, status) ~ 1, data = dane_fh, type="fh")
  wyniki_fh <- data.frame(time = fh_fit$time, surv = fh_fit$surv)

  punkt_startowy <- data.frame(time = 0, surv = 1)

  dane_fh_uzupelnione <- bind_rows(punkt_startowy, wyniki_fh) %>%
    arrange(time) %>%
    distinct(time, .keep_all = TRUE)

  czasy <- dane_fh_uzupelnione$time
  S_t   <- dane_fh_uzupelnione$surv

  a <- S_t[-length(S_t)]
  b <- diff(czasy)
  I_1 <- sum(a*b)

  t_plus <- max(fh_fit$time)
  S_t_plus <- S_t[length(S_t)]

  czy_cenzurowana <- (fh_fit$n.event[length(fh_fit$n.event)] == 0)
```

```
  if (!czy_cenzurowana || S_t_plus <= 0) {
    I_2 <- 0
  } else {
    theta <- -log(S_t_plus)/t_plus
    I_2 <- S_t_plus/theta
  }

  sredni_czas_zycia <- I_1 + I_2
  return(sredni_czas_zycia)
}
```

Jeżeli rozważymy przykładowe czasy do wystapięnia zdarzenia $2, 3, 1, 4, 5, 7, 9, 12, 14, 18$ oraz odpowiadające im indykatory cenzurowania $0, 1, 1, 0, 1, 0, 1, 0, 1, 0$ to estymowany średni czas życia w oparciu o estymator Kaplana-Meiera z opcją szacowania ogona zaproponowaną przez Browna, Hollandera i Kowara będzie wynosił 13.6047651, natomiast to estymowany średni czas życia w oparciu o estymator Fleminga-Harringtona z opcją szacowania ogona zaproponowaną przez Browna, Hollandera i Kowara będzie wynosił 16.0536473.

2.2 Zadanie 2

Celem tego zadania jest oszacowanie średnich czasów do remisji choroby dla dwóch grup pacjentów otrzymujących leki A i B. Wartości te będą szacowane w oparciu o estymator Kaplana-Meiera i estymator Fleminga-Harringtona, przy wykorzystaniu zaimplementowanych w poprzednim zadaniu funkcji `estymacja_sr_czasu_zycia_km` i `estymacja_sr_czasu_zycia_fh` estymujących średni czas życia w oparciu o odpowiednio estymator Kaplana-Meiera i estymator Fleminga-Harringtona.

```
T_A_zdarzenia <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
 ↪  0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)
T_A_zdarzenia_ocenzurowane <- rep(1, 10)
T_A <- c(T_A_zdarzenia, T_A_zdarzenia_ocenzurowane)
E_A <- c(rep(1, 10), rep(0, 10))

T_B_zdarzenia <-  c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
 ↪  0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.69119721)
T_B_zdarzenia_ocenzurowane <- rep(1, 10)
T_B <- c(T_B_zdarzenia, T_B_zdarzenia_ocenzurowane)
E_B <- c(rep(1, 10), rep(0, 10))

tabela_wyniki <- data.frame(
  Lek = c("A", "B"),
  `Estymator Kaplana-Meiera` = c(estymacja_sr_czasu_zycia_km(T_A, E_A),
   ↪  estymacja_sr_czasu_zycia_km(T_B, E_B)),
  `Estymator Fleminga-Harringtona` = c(estymacja_sr_czasu_zycia_fh(T_A, E_A),
   ↪  estymacja_sr_czasu_zycia_fh(T_B, E_B)),
  check.names = FALSE)
```

Tabela 1: Wartości oszacowań uzyskane w oparciu o estymator Kaplana-Meiera i Fleminga-Harringtona

Lek	Estymator Kaplana-Meiera	Estymator Fleminga-Harringtona
A	1.43	1.48
B	1.39	1.45

Na podstawie tabeli widać, że estymowany średni czas do remisji choroby pacjentów leczonych lekiem A jest dłuższy od tego dla pacjentów leczonych lekiem B niezależnie od wybranej metody estymacji. Metoda Fleminga-Harringtona dała nieco wyższe wartości średniej niż metoda Kaplana-Meiera.

3 Lista 7

3.1 Zadanie 1

Celem tego zadania jest wyznaczenie asymptotycznego punktowo przedziału ufności dla wartości średniej czasu życia na poziomie ufności $1 - \alpha$. W tym celu napiszemy funkcję `est_czas_zycia`, której argumentami będą dane cenzurowane losowo, wartość poziomu ufności oraz wartość τ.

```
library(survival)
library(knitr)

est_czas_zycia <- function(time, delta, conf_level = 0.95, tau) {

  fit_km <- survfit(Surv(time, delta) ~ 1)

  km_summary <- data.frame(
    time = fit_km$time,
    surv = fit_km$surv,
    n_risk = fit_km$n.risk,
    n_event = fit_km$n.event
  )

  t_points <- c(0, km_summary$time[km_summary$time < tau], tau)

  S_points <- c(1, km_summary$surv[km_summary$time < tau],
                summary(fit_km, times = tau, extend = TRUE)$surv)

  dane <- unique(data.frame(time = t_points, surv = S_points))
  dane <-  dane[order(dane$time), ]

  t_max_km <- max(fit_km$time)
  S_tmax <- tail(fit_km$surv, 1)

  # obliczenie estymatora sredniej (16)
  est_sred <- 0
  for (i in 1:(nrow(dane) - 1)) {
    t_start <- dane$time[i]
    t_end <- dane$time[i+1]
    S_obecny <- dane$surv[i]
    est_sred <- est_sred + S_obecny * (t_end - t_start)
  }

  # obliczenie estymatora wariancji (17)
  events_df <- km_summary[km_summary$n_event > 0 & km_summary$time <= tau, ]
  est_var <- 0
```

```r
  for (i in 1:nrow(events_df)) {
    s_i <- events_df$time[i]
    d_i <- events_df$n_event[i]
    r_i <- events_df$n_risk[i]

    calka <- 0
    punkty_calk <- dane[dane$time >= s_i & dane$time <= tau, ]

    for (j in 1:(nrow(punkty_calk) - 1)) {
      t_start_j <- punkty_calk$time[j]
      t_end_j <- punkty_calk$time[j+1]

      S_obecny_j <- punkty_calk$surv[j]

      if (t_start_j >= t_max_km) {
        S_obecny_j <- S_tmax
      }

      calka <- calka + S_obecny_j * (t_end_j - t_start_j)
    }

    # dodanie składnika do wariancji
      est_var <- est_var + (calka^2) * (d_i / (r_i * (r_i - d_i)))

  }

  # granice przedziału ufności
  alpha <- 1 - conf_level
  z <- qnorm(1 - alpha / 2)

  T_L <- est_sred - z * sqrt(est_var)
  T_U <- est_sred + z * sqrt(est_var)

  return(c(est_sred = est_sred, T_L = T_L, T_U = T_U))
}
```

3.2 Zadanie 2

W tym zadaniu mamy dane z badania przeprowadzonego u pacjentek z rakiem jajnika. Jego celem było ustalenie czy stopień zaawansowania choroby był związany z czasem do progresji choroby. Pacjenki zostaly podzielone na dwie grupy ze względu na stopień zaawansowania choroby. Skorzystamy z naszej funkcji `est_czas_zycia`, aby wyznaczyć realizacje przedziałów ufności na poziomie ufności 0.95, dla średniego czasu do progresji choroby w dwóch badanych grupach pacjentek.

```r
# niski stopien zaaw.
time_low <- c(28, 89, 175, 195, 309, 377, 393, 421, 447, 462, 709, 744, 770,
 ↪  1106, 1206)
delta_low <- c(1, 1, 1, 1, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0)

# wysoki stopien zaaw.
time_high <- c(34, 88, 137, 199, 280, 291, 299, 300, 309, 351, 358, 369, 369,
 ↪  370, 375, 382, 392, 429, 451, 1119)
delta_high <- c(1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 0)

low_1500 <- est_czas_zycia(time_low, delta_low, conf_level = 0.95, tau = 1500)
high_1500 <- est_czas_zycia(time_high, delta_high, conf_level = 0.95, tau = 1500)

low_1600 <- est_czas_zycia(time_low, delta_low, conf_level = 0.95, tau = 1600)
high_1600 <- est_czas_zycia(time_high, delta_high, conf_level = 0.95, tau = 1600)


results_df <- data.frame(
  Grupa = rep(c("Niskie zaawansowanie", "Wysokie zaawansowanie"), each = 2),
  Tau = c(1500, 1600, 1500, 1600),
  est_sredniej = c(low_1500["est_sred"], low_1600["est_sred"],
                   high_1500["est_sred"], high_1600["est_sred"]),
  Dolna_Granica = c(low_1500["T_L"], low_1600["T_L"],
                    high_1500["T_L"], high_1600["T_L"]),
  Gorna_Granica = c(low_1500["T_U"], low_1600["T_U"],
                    high_1500["T_U"], high_1600["T_U"])
)
```

Tabela 2: Realizacje przedziałów ufności dla średniego czasu do progresji choroby

Grupa	τ	$\hat{\mu}_\tau$ (dni)	Dolna Granica	Górna Granica
Niskie zaawansowanie	1500	937.73	589.91	1285.56
Niskie zaawansowanie	1600	993.29	617.72	1368.86
Wysokie zaawansowanie	1500	413.20	232.73	593.67
Wysokie zaawansowanie	1600	421.95	226.94	616.96

Wnioski:

- Grupa o niskim stopniu zaawansowania choroby ma znacznie lepsze rokowanie. Średni czas do progresji choroby ($\hat{\mu}_\tau$) dla tej grupy jest ponad dwukrotnie dłuższy niż dla grupy o wysokim stopniu zaawansowania, niezależnie od przyjętego τ. Dla $\tau = 1500$ dni: $\hat{\mu}$ dla niskiego zagrożenia wynosi 937.7 dni, natomiast dla wysokiego zagrożenia 413.2 dni.
- Możemy zauważyć, iż przedziały ufności dla niskiego i wysokiego zaawansowania praktycznie nie nachodzą na siebie. Oznacza to, że różnica w czasie przeżycia między tymi grupami jest statystycznie istotna.
- Dłuższy horyzont czasowy (τ) daje wyższe średnie: Kiedy wydłużamy horyzont z $\tau = 1500$ do $\tau = 1600$ dni, średni czas do progresji ($\hat{\mu}_\tau$) wzrasta w obu grupach (np. z 937.7 do 993.2 dni w grupie niskiego zaawansowania).
- Dodatkowo, zwiększenie τ z 1500 do 1600 dni powoduje, że przedziały ufności stają się szersze. Oznacza to, że nasza estymacja jest mniej precyzyjna, gdy próbujemy prognozować na dłuższy okres czasu.

4 Lista 8

4.1 Zadanie 1

Celem tego zadania jest weryfikacja hipotezy $H_0 : S_1(t) = S_2(t)$, mówiącej o jednakowym rozkładzie czasu do progresji choroby w dwóch badanych grupach pacjentek, grupie z niskim stopniem zaawansowania choroby i grupie z wysokim stopniem zaawansowania choroby.Hipoteza jest weryfikowana na poziomie istotności $\alpha = 0.05$ Do weryfikacji hipotezy zostaną wykorzystane testy **log-rank**, **Gehana-Breslowa**, **Tarone'a-Warego** i **Peto-Peto**.

Wszystkie wyżej wymienione testy opierają sie na statystyce Z^2, która dąży do rozkładu χ^2 z $k-1$ stopniami swobody, jeśli H_0 jest prawdziwa i wykorzystują sumę ważonych różnic $Z_j(\tau)$:

$$Z_j(\tau) = \sum_{i=1}^{D} W(t_i) \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right), \quad j = 1, ..., k$$

gdzie:

- t_i - uporządkowane czasy zdarzeń
- D - liczba zdarzeń niecenzurowanych we wszystkich próbach
- d_{ij} - liczba zdarzeń w czasie t_i z próby X_j
- r_{ij} - liczba jednostek w stanie ryzyka w czasie t_i w j-tej grupie
- $d_i = \sum_{j=1}^{k} d_{ij}$
- $r_i = \sum_{j=1}^{k} r_{ij}$

i różnią się funkcją wagową W.

- **Test log-rank**

Test ten uzyskuje się, przyjmując funkcję wagową $W(t_i) = 1$:

$$Z_j(\tau) = \sum_{i=1}^{D} \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right)$$

- **Test Gehana-Breslowa**

Test ten uzyskuje się, przyjmując funkcję wagową $W(t_i) = r_i$:

$$Z_j(\tau) = \sum_{i=1}^{D} r_i \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right)$$

* **Test Tarone'a-Ware'a**

Test ten jest przykładem ogólnej klasy testów, w której $W(t_i) = f(r_i)$. Użyjemy wariantu, w którym $f(t_i) = \sqrt{r_i}$:

$$Z_j(\tau) = \sum_{i=1}^{D} \sqrt{r_i} \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right)$$

- **Test Peto-Peto**

Test ten uzyskuje się, przyjmując funkcję wagową $W(t_i) = \tilde{S}(t_i) = \prod_{t_j \leq t_i} \left(1 - \frac{d_j}{r_j+1}\right)$:

$$Z_j(\tau) = \sum_{i=1}^{D} \left[\prod_{t_l \leq t_i} \left(1 - \frac{d_l}{r_l + 1}\right) \right] \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right)$$

Do wyznaczenia testów i wartości ich poziomów krytycznych wykorzystana zostanie funkcja `logrank_test` z pakietu `coin` z odpowiednim argumentem `type`.

```
library(survival)
library(coin)

czasy_niskie <- c(28, 89, 175, 195, 309, 377, 393, 421, 447, 462, 709, 744, 770,
 ↪  1106, 1206)
czasy_wysokie <- c(34, 88, 137, 199, 280, 291, 299, 300, 309, 351, 358, 369, 369,
 ↪  370, 375, 382, 392, 429, 451, 1119)

cenzura_niskie <- c(1, 1, 1, 1, 1, 0, 0, 0, 0, 1, 0, 0, 0, 0, 0)
cenzura_wysokie <- c(1, 1, 1, 1, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 0)

pacjentki_niski <- rep("Niski stopień", length(czasy_niskie))
pacjentki_wysoki <- rep("Wysoki stopień", length(czasy_wysokie))

grupa <- factor(c(pacjentki_niski, pacjentki_wysoki))

dane_pacjentki <- data.frame(
  czasy = c(czasy_niskie, czasy_wysokie),
  status = c(cenzura_niskie, cenzura_wysokie),
  grupa = grupa)

test_logrank <- logrank_test(Surv(czasy, status) ~ grupa, data = dane_pacjentki,
 ↪  type = "logrank")
poziom_krytyczny_logrank <- pvalue(test_logrank)

test_gehan_breslow <- logrank_test(Surv(czasy, status) ~ grupa, data =
 ↪  dane_pacjentki, type = "Gehan-Breslow")
poziom_krytyczny_gehan_breslow <- pvalue(test_gehan_breslow)
```

```r
test_tarone_ware <- logrank_test(Surv(czasy, status) ~ grupa, data =
 ↪  dane_pacjentki, type = "Tarone-Ware")
poziom_krytyczny_tarone_ware <- pvalue(test_tarone_ware)

test_peto_peto <- logrank_test(Surv(czasy, status) ~ grupa, data =
 ↪  dane_pacjentki, type = "Peto-Peto")
poziom_krytyczny_peto_peto <- pvalue(test_peto_peto)
```

Tabela 3: Wartości poziomów krytycznych w testach

Test	p-value
log-rank	0.02
Gehan-Breslow	0.13
Tarone-Ware	0.06
Peto-Peto	0.10

Na podstawie tabeli widać, że dla testu **log-rank** należy odrzucić hipotezę $H_0 : S_1(t) = S_2(t)$ na poziomie istotności $\alpha = 0.05$, natomiast dla testów **Gehana-Breslowa**, **Tarone'a-Warego** i **Peto-Peto** nie mamy podstaw do odrzucenia H_0. Jest to najprawdopodobniej spowodowane tym, że test **log-rank** stosuje wagę stałą w całym okresie obserwacji, co wskazuje na istotne zróżnicowanie ryzyka w późniejszych fazach obserwacji. Pozostałe testy dają większy nacisk wczesnym zdarzeniom, a ich nieistotność świadczy o braku istotnych różnic w ryzyku progresji na początku obserwacji.

4.2 Zadanie 2

Celem tego zadania jest graficzna analiza rozkładów czasu do progresji choroby w dwóch badanych grupach pacjentek, za pomocą estymatora Kaplana-Meiera funkcji przeżycia $S(t)$ oraz wizualizacja funkcji wagowych użytych w testach **log-rank**, **Gehana-Breslowa**, **Tarone'a-Warego** i **Peto--Peto**, która pokaże wpływ "ważenia" zdarzenia w czasie, na różnice w wartościach poziomów krytycznych poszczególnych testów.

```
library(survminer)
library(survival)
library(ggplot2)

fit <- survfit(Surv(czasy, status) ~ grupa, data = dane_pacjentki)

ggsurvplot(fit, data = dane_pacjentki, pval = TRUE, conf.int = TRUE, risk.table =
 ↪  TRUE, risk.table.col = "strata", legend.title = "Stopień \n zaawansowania",
 ↪  legend.labs = c("Niski stopień", "Wysoki stopień"),title = "Estymatory
 ↪  Kaplana-Meiera funkcji przeżycia dla obu grup",  xlab = "Czas (dni)", ylab =
 ↪  "Prawdopodobieństwo przeżycia (S(t))", ggtheme = theme_bw())
```

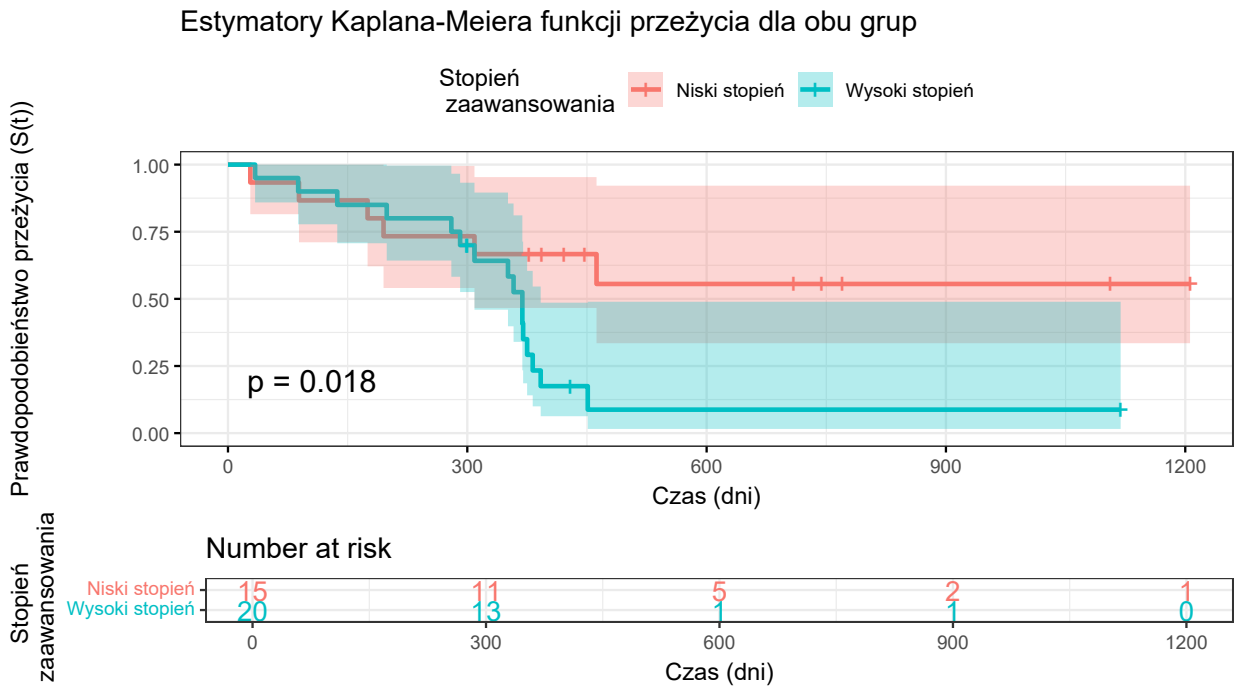

Na podstawie wykresu widać, że rozkłady czasu do progresji choroby przestają być podobne dopiero po dłuższym upływie czasu. Warto jednak zauważyć, że obie grupy mają zdecydowanie więcej wczesnych progresji.

```r
library(reshape2)

fit <- survfit(Surv(czasy, status) ~ 1, data = dane_pacjentki)
czas_zdarzenia <- fit$time
r_i <- fit$n.risk
funkcja_przezycia <- fit$surv

wagi <- data.frame(
  Czas = czas_zdarzenia,
  "Log-rank" = 1,
  "Gehan-Breslow" = r_i / max(r_i),
  "Tarone-Ware" = sqrt(r_i) / max(sqrt(r_i)),
  "Peto-Peto" = funkcja_przezycia)

wagi <- melt(wagi, id.vars = "Czas", variable.name = "Test", value.name = "Waga")

ggplot(wagi, aes(x = Czas, y = Waga, color = Test)) + geom_step(linewidth = 1)  +
↪  theme_bw() +  labs(title = "Porównanie znormalizowanych funkcji wagowych
↪  testów", y = "Waga (znormalizowana)", x = "Czas (dni)") +
↪  theme(legend.position = "top")
```

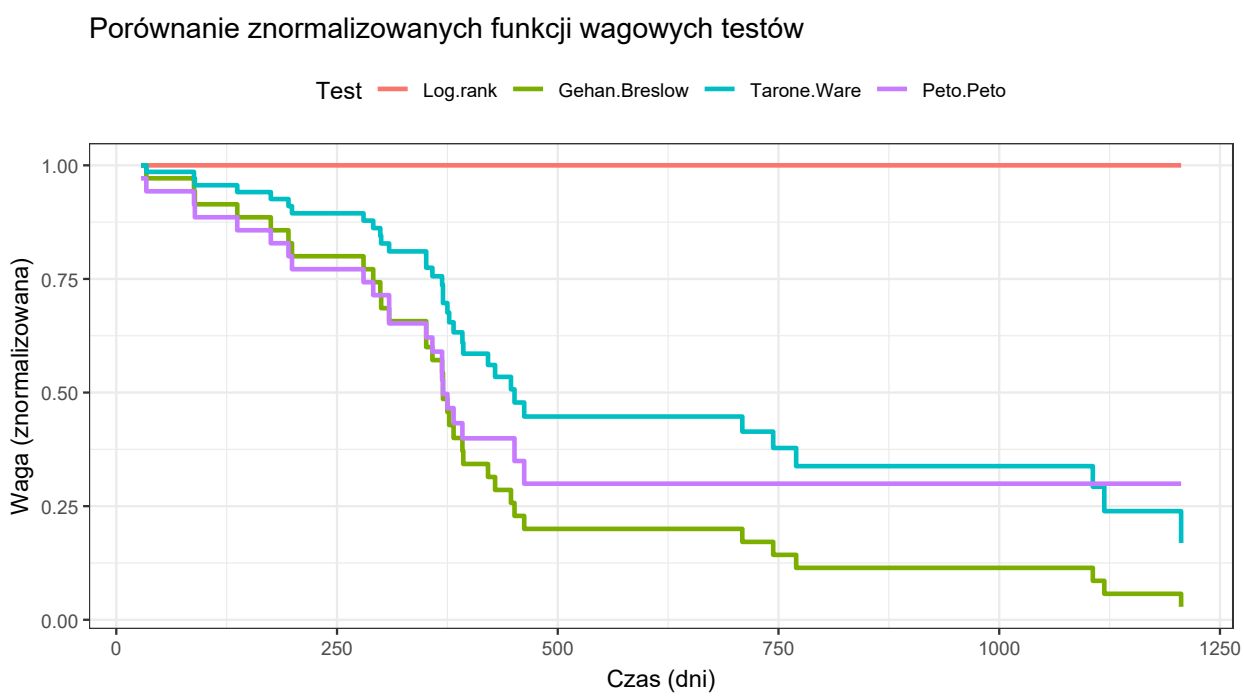

Na podstawie wykresu widać, że test **log-rank** stosuje wagę stałą w całym okresie obserwacji, natomiast pozostałe testy dają większy nacisk wczesnym zdarzeniom.

Testy **Gehana-Breslowa**, **Tarone-Ware'a** i **Peto-Peto** przypisują największe znaczenie zdarzeniom z początku obserwacji, przez co silnie reagują na różnice pojawiające się wcześnie. W naszych danych szczególnie grupa o wysokim stopniu zaawansowania ma więcej wczesnych progresji, co prowadzi do niskich wartości p w tych testach.

Test **log-rank** traktuje wszystkie zdarzenia jednakowo, więc pomija wczesne różnice, ponieważ później krzywe przeżycia obu grup zaczynają się do siebie zbliżać. W efekcie daje on wynik nieistotny statystycznie.