Sprawozdanie 3

Analiza Przeżycia

Dominik Działowski, Mateusz Skuza

2026-03-29

Spis treści

1 Wstęp **3**

2 Lista 9 **4**

2.1 Zadanie 1 4

2.2 Zadanie 2 5

2.3 Zadanie 3 6

2.4 Zadanie 4 7

2.5 Zadanie 5 8

2.6 Zadanie 6 9

2.7 Zadanie 7 10

2.8 Zadanie 8 12

2.9 Zadanie 9 13

3 Lista 10 **14**

3.1 Zadanie 1 14

3.2 Zadanie 2 15

3.3 Zadanie 3 15

3.4 Zadanie 4 16

3.5 Zadanie 5 17

3.6 Zadanie 6 18

4 Lista 11 **19**

4.1 Zadanie 1 19

4.2 Zadanie 2 20

4.3 Zadanie 3 20

4.4 Zadanie 4 21

4.5 Zadanie 5 24

4.6 Zadanie 6 25

5 Lista 12 **26**

5.1 Zadanie 1 26

5.2 Zadanie 2 28

1 Wstęp

Sprawozdanie będzie dotyczyć danych *lung* z biblioteki *survival*, dotyczących danych o 228 pacjentach z zaawansowanym rakiem płuc. Zbiór zawiera następujące informacje o pacjentach:

- *inst*: kod instytucji,
- *time*: czas przeżycia w dniach,
- *status*: cenzura (1 - cenzura, 2 - śmierć)

oraz ich następujące charakterystyki:

- *age*: wiek (w latach),
- *sex*: płeć (1 - mężczyzna, 2 - kobieta),
- *ph.ecog*: skala sprawności ECOG wg. lekarza (0-sprawność prawidłowa, 5-zgon)
- *ph.karno*: skala sprawnosci Karnofsky'ego wg. lekarza (100-sprawność prawidłowa, 0-zgon),
- *pat.karno*: skala sprawności Karnofsky'ego wg. pacjenta,
- *meal.cal*: kalorie spożywane podczas posiłków,
- *wt.loss*: utrata masy ciała w ciągu ostatnich sześciu miesięcy.

Do analizy danych przyjmujemy, że czas przeżycia ma rozkład Weibulla.

2 Lista 9

2.1 Zadanie 1

Celem tego zadania jest oszacowanie parametrów modelu przyspieszonego czasu awarii. Wykorzystana do tego zostanie funkcja `survreg`, do której wykorzystuje się model liniowy logarytmu czasu życia zdefiniowany wzorem:

$$\ln(X_z) = \mu - \beta^T z + \sigma W$$

gdzie:

- X_z to czas do wystąpienia zdarzenia,
- μ to parametr położenia,
- β^T to wektor współczynników regresji,
- z to wektor charakterystyk,
- σ to parametr skali,
- W to zmienna losowa błędu o znanej postaci rozkładu.

W naszym przypadku, gdzie za zmienna zależną przyjmiemy zmienną *time* a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*, model będzie zakładał zależność:

$$\ln(X_z) = \mu - (\beta_{age}\text{age} + \beta_{sex}\text{sex} + \beta_{ph.ecog}\text{ph.ecog} + \beta_{ph.karno}\text{ph.karno}) + \sigma W$$

Przed oszacowaniem parametrów należy odpowiednio przygotować dane poprzez wybranie odpowiednich kolumn, usunięcie wierszy z brakującymi danymi, zcentrowanie zmiennych ilościowych czyli *age* i *ph.karno* oraz zamiane typu zmiennych *sex* i *ph.ecog* z `numeric` na `factor`.

```r
library(survival)
data(lung)

lung_1 <- na.omit(lung[, c("time", "status", "age", "sex", "ph.ecog",
 ↪  "ph.karno")])

lung_1$age_centered <- lung_1$age - mean(lung_1$age)
lung_1$ph.karno_centered <- lung_1$ph.karno - mean(lung_1$ph.karno)
lung_1$sex <- as.factor(lung_1$sex)
lung_1$ph.ecog <- as.factor(lung_1$ph.ecog)

model_aft <- survreg(Surv(time, status) ~ age_centered + sex + ph.ecog +
 ↪  ph.karno_centered, data = lung_1, dist = "weibull")
```

Wyniki estymacji parametrów modelu są następujące:

```
##       (Intercept)      age_centered              sex2          ph.ecog1
##       6.301180488      -0.008601783       0.408280141      -0.421560818
##          ph.ecog2          ph.ecog3 ph.karno_centered
##      -0.926113456      -1.687243371      -0.010056702
```

2.2 Zadanie 2

Według założonej postaci modelu AFT $\ln(X_z) = \mu - \beta^T z + \sigma W$ ujemny współczynnik β oznacza skrócenie oczekiwanego czasu przeżycia, natomiast dodatni oznacza wydłużenie oczekiwanego czasu przeżycia.

- $\beta_{age} = -0.08$ sygnalizuje, że jednostka starsza ma w każdej chwili większe prawdopodobieństwo wystąpienia zgonu od jednostki młodszej.
- $\beta_{sex} = 0.408$ oznacza, że bycie kobietą istotnie opóźnia czas do wystąpienia zgonu.
- $\beta_{ph.ecog1} = -0.422$, $\beta_{ph.ecog2} = -0.926$, $\beta_{ph.ecog3} = -1.687$ oznaczają, że im wyższa wartość współczynnika *ph.ecog*, tym większe prawdopodobieństwo na szybsze wystąpienie zgonu.
- $\beta_{ph.karno} = -0.01$ wskazuje na to, że jednostka z wyższym wynikiem punktowym posiada większe prawdopodobieństwo wystąpienia zgonu niż jednostka o niższym wyniku.

2.3 Zadanie 3

W tym zadaniu należy oszacować funkcję przeżycia, która będzie odpowiadać rozkładowi czasu życia pacjentki o pewnych charakterystykach, a następnie na podstawie uzyskanego oszacowania obliczyć szacowane prawdopodobieństwo, że czas życia tej kobiety będzie większy niż 300 dni.

Do tego zadania można wykorzystać fakt, że w modelu liniowym logarytmu czasu życia wykorzystywanym przez funkcję `survreg`, zależność parametrów rozkładu Weibulla od charakterystyk z, można wyrazić poprzez parametr skali

$$\lambda_z = \lambda_0 \exp(-\alpha_0 \beta^T z),$$

i parametr kształtu α_0, gdzie $\lambda_0 = \exp(-\mu/\sigma)$ i $\alpha_0 = 1/\sigma$.

Wówczas funkcja przeżycia jest postaci:

$$S(t|z) = \exp(-\lambda_z t^{\alpha_0}) = \exp(-\lambda_0 \exp(-\alpha_0 \beta^T z) t^{\alpha_0})$$

Na podstawie powyższego wzoru zaimplementowana zostanie funkcja `estymator_funkcji_przezycia_pacjentki`, która będzie szacować prawdopobodobieństwo przeżycia tej pacjentki przez dany okres czasu t (w dniach). Współczynniki β przyjmujemy z modelu AFT z zadania 1.

```
age_centered_1 <- 70 - mean(lung_1$age)
ph.karno_centered_1 <- 90 - mean(lung_1$ph.karno)

mu <- model_aft$coefficients["(Intercept)"]
sigma <- model_aft$scale
alpha_0 <- 1/sigma
lambda_0 <- exp(-mu/sigma)

beta_z <- model_aft$coefficients["age_centered"]*age_centered_1 +
 ↪  model_aft$coefficients["sex2"] + model_aft$coefficients["ph.ecog1"] +
 ↪  model_aft$coefficients["ph.karno_centered"]*ph.karno_centered_1

lambda_z <- lambda_0*exp(-alpha_0*beta_z)

estymator_funkcji_przezycia_pacjentki <- function(t){
  exp(-lambda_z*t^alpha_0)
}
```

Gdy $t = 300$, to badamy szacowane prawdopodobieństwo, że czas życia tej kobiety będzie większy niż 300 dni. To prawdopodobieństwo wynosi około 0.5806085.

2.4 Zadanie 4

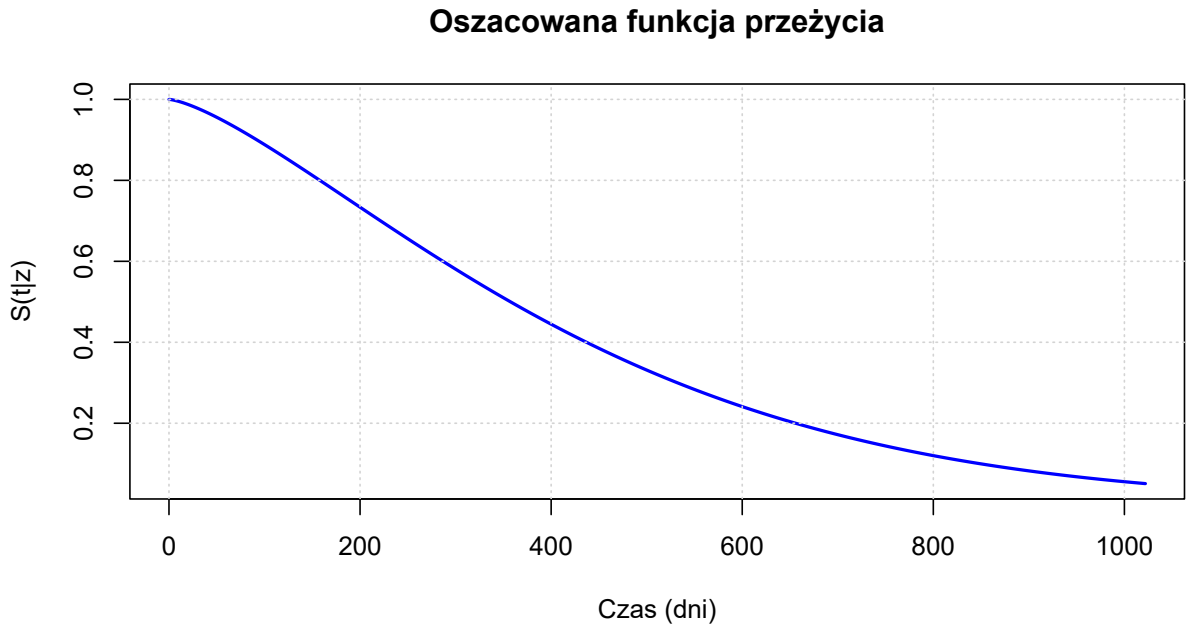

Rysunek 1: Wykres oszacowanej w zadaniu 3 funkcji przeżycia

2.5 Zadanie 5

Celem tego zadania jest oszacowanie parametrów modelu proporcjonalnych hazardów. Wykorzystana do tego zostanie funkcja `phreg` z biblioteki `eha` , która opiera się na modelu zdefiniowanym wzorem:

$$h(t|z) = h_0(t)\exp(\beta^T z)$$

gdzie:

- $h(t|z)$ to funkcja hazardu dla jednostki o wektorze charakterystyk z,
- $h_0(t)$ to bazowa funkcja hazardu,
- β^T to wektor współczynników regresji,
- z to wektor charakterystyk.

W naszym przypadku przyjmujemy, że czas przeżycia ma rozkład Weibulla, więc bazowa funkcja hazardu $h_0(t) = \lambda_0\alpha_0 t^{\alpha_0-1}$. Gdy za zmienna zależną przyjmiemy zmienną *time* a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*, model będzie zakładał zależność:

$$h(t|z) = \lambda_0\alpha_0 t^{\alpha_0-1}\exp(\beta_{age}\text{age} + \beta_{sex}\text{sex} + \beta_{ph.ecog}\text{ph.ecog} + \beta_{ph.karno}\text{ph.karno})$$

```
library(eha)

model_ph <- phreg(Surv(time, status) ~ age_centered + sex + ph.ecog +
 ↪  ph.karno_centered, data=lung_1, dist="weibull")
```

Wyniki estymacji parametrów modelu są następujące:

```
##      age_centered              sex2          ph.ecog1          ph.ecog2
##        0.01193610       -0.56654199        0.58497067        1.28510332
##          ph.ecog3 ph.karno_centered        log(scale)        log(shape)
##        2.34127043        0.01395499        6.30118049        0.32759765
```

2.6 Zadanie 6

W modelu proporcjonalnych hazardów $h(t|z) = h_0(t)\exp(\beta^T z)$ dodatnia wartość współczynnika β oznacza wzrost hazardu (intensywności zgonu), co skutkuje skróceniem czasu przeżycia. Wartość ujemna oznacza zmniejszenie hazardu i wydłużenie czasu przeżycia.

- $\beta_{age} = 0.012$ sygnalizuje, że jednostka starsza ma w każdej chwili większe prawdopodobieństwo wystąpienia zgonu (wyższy hazard) od jednostki młodszej.
- $\beta_{sex} = -0.567$ oznacza, że bycie kobietą istotnie zmniejsza intensywność wystąpienia zgonu.
- $\beta_{ph.ecog1} = 0.585$, $\beta_{ph.ecog2} = 1.285$, $\beta_{ph.ecog3} = 2.341$ oznaczają, że im wyższa wartość współczynnika *ph.ecog*, tym większe prawdopodobieństwo na szybsze wystąpienie zgonu.
- $\beta_{ph.karno} = 0.014$ wskazuje na to, że jednostka z wyższym wynikiem punktowym posiada większe prawdopodobieństwo wystąpienia zgonu niż jednostka o niższym wyniku.

2.7 Zadanie 7

W tym zadaniu należy oszacować i porównać funkcje hazardu i logarytmy tych funkcji dla dwóch pacjentek o pewnych charakterystykach.

Do wyznaczenia oszacowania funkcji hazardu wykorzystamy wzór:

$$h(t|z) = \lambda_0 \alpha_0 t^{\alpha_0 - 1} \exp(\beta^T z)$$

gdzie parametry kształtu $\alpha_0 = 1/\sigma$ i skali $\lambda_0 = \exp(-\mu/\sigma)$ oraz współczynniki β przyjmujemy bezpośrednio z modelu PH. Ponieważ model zakłada proporcjonalność hazardów, logarytm funkcji hazardu:

$$\ln h(t|z) = \ln(\lambda_0 \alpha_0) + (\alpha_0 - 1)\ln(t) + \beta^T z$$

powinien dla obu pacjentek różnić się jedynie o wartość $\beta^T(z_b - z_a)$. Do wyznaczenia tego oszacowania zostanie zaimplementowana funkcja `estymator_funkcji_hazardu_pacjentek` szacująca ryzyko zgonu pacjentek przez dany okres czasu t (w dniach).

```
mu_ph <- model_ph$coefficients[7]
sigma_ph <- exp(-model_ph$coefficients[8])

alpha_0_1 <- 1/sigma_ph
lambda_0_1 <- exp(-mu_ph/sigma_ph)

beta_z_a <- model_ph$coefficients["age_centered"]*age_centered_1 +
 ↪  model_ph$coefficients["sex2"] +
 ↪  model_ph$coefficients["ph.karno_centered"]*ph.karno_centered_1 +
 ↪  model_ph$coefficients["ph.ecog1"]

beta_z_b <- model_ph$coefficients["age_centered"]*age_centered_1 +
 ↪  model_ph$coefficients["sex2"] +
 ↪  model_ph$coefficients["ph.karno_centered"]*ph.karno_centered_1 +
 ↪  model_ph$coefficients["ph.ecog2"]

estymator_funkcji_hazardu_pacjentek <- function(t, beta_z){
  lambda_0_1*alpha_0_1*t^(alpha_0_1-1)*exp(beta_z)
}

szacowany_hazard_pacjentka_a <- estymator_funkcji_hazardu_pacjentek(przedzial_t,
 ↪  beta_z_a)
szacowany_hazard_pacjentka_b <- estymator_funkcji_hazardu_pacjentek(przedzial_t,
 ↪  beta_z_b)
```

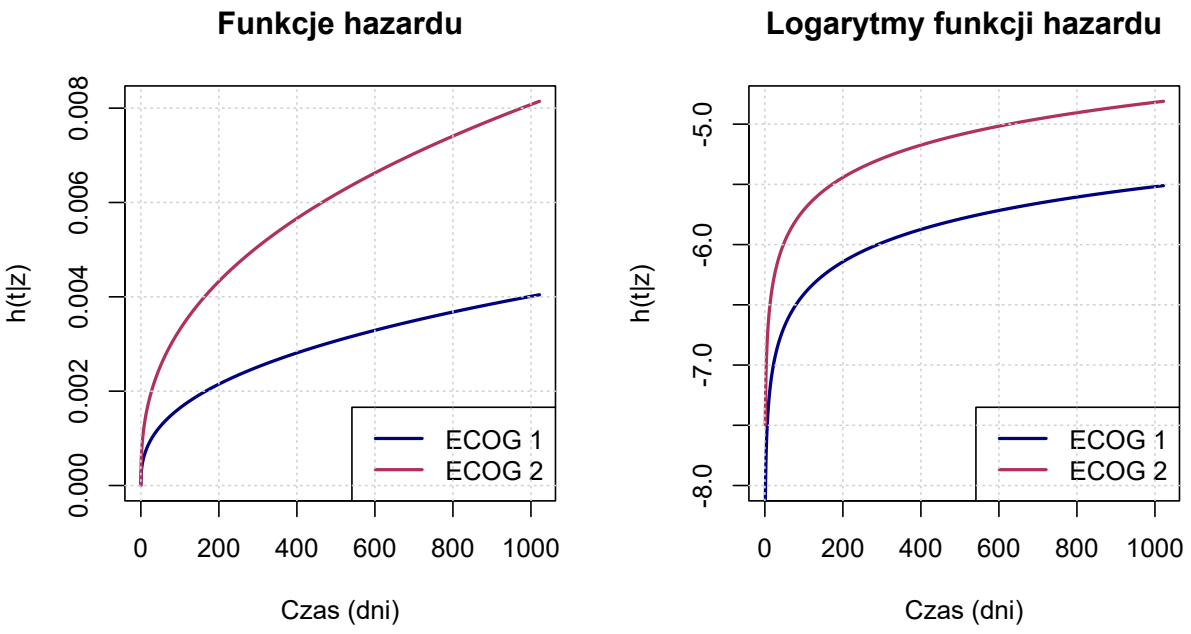

Rysunek 2: Porównanie funkcji hazardu i ich logarytmów dla dwóch pacjentek

Na podstawie wykresów widać, że wyraźniejsze ryzyko zgonu w każdej chwili ma pacjentka o gorszej sprawności, a wykresy logarytmów funkcji hazardu są do siebie równoległe, co jest zgodne z prawdą. Nie mamy zatem podstaw do podważania przyjętego modelu proporcjonalnych hazardów.

2.8 Zadanie 8

W tym zadaniu należy oszacować i porównać funkcje przeżycia odpowiadające rozkładowi czasu życia dla dwóch pacjentek o różnych stopniach sprawności, a następnie na podstawie uzyskanego oszacowania obliczyć szacowane prawdopodobieństwo, że czas życia tych kobiet będzie większy niż 300 dni.

Do rozwiązania tego zadania wykorzystamy fakt, że w modelu proporcjonalnych hazardów z bazowym rozkładem Weibulla funkcja przeżycia dana jest wzorem:

$$S(t|z) = \exp(-\lambda_z t^{\alpha_0}) = \exp(-\lambda_0 \exp(\beta^T z) t^{\alpha_0}).$$

Na podstawie powyższego wzoru zaimplementowana zostanie funkcja `estymator_funkcji_przezycia_pacjentek` , która będzie szacować prawdopobodobieństwo przeżycia tych pacjentek przez dany okres czasu t (w dniach). Parametry kształtu $\alpha_0 = 1/\sigma$ i skali $\lambda_0 = \exp(-\mu/\sigma)$ oraz współczynniki β przyjmujemy bezpośrednio z modelu PH. Do wyznaczenia tego oszacowania zostanie zaimplementowana funkcja `estymator_funkcji_przezycia_pacjentek` szacująca prawdopobodobieństwo przeżycia pacjentek przez dany okres czasu t (w dniach).

```
estymator_funkcji_przezycia_pacjentek <- function(t, beta_z){
  exp(-lambda_0_1*exp(beta_z)*t^alpha_0_1)
}
```

Gdy $t = 300$, to badamy szacowane prawdopodobieństwo, że czas życia tych kobiet będzie większy niż 300 dni. To prawdopodobieństwo wynosi w przypadku pierwszej pacjentki z lepszą sprawnością około 0.5806085 (oszacowanie dla tej pacjentki wynosi dokładnie tyle samo co w zadaniu 3), natomiast w przypadku drugiej pacjentki z gorszą sprawnością około 0.3345465.

2.9 Zadanie 9

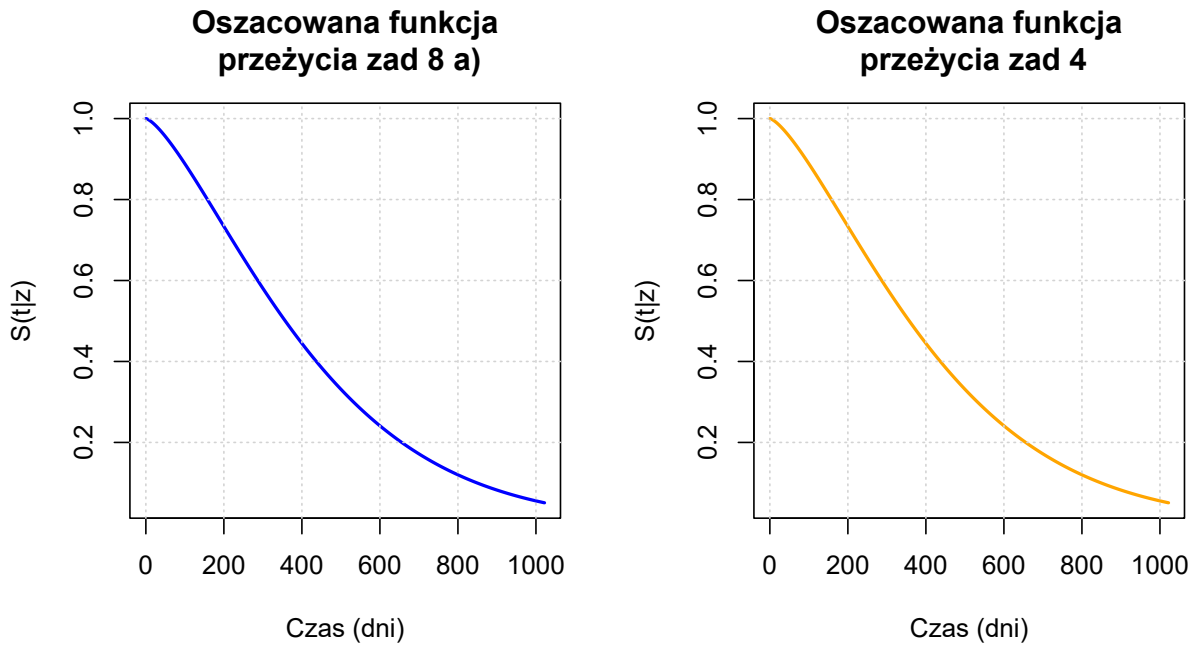

Rysunek 3: Porównanie oszacowanych na podstawie parametrów uzyskanych z modeli PH i AFT funkcji przeżycia odpowiadających rozkładowi czasu życia pacjentki

Wykresy funkcji przeżycia uzyskane z modelu AFT oraz modelu PH są identyczne.

3 Lista 10

Na tej liście, będziemy korzystać, z tych samych danych co na liście 9 - `lung` i nie będziemy przyjmować żadnego konkretnego rozkładu czasu życia.

3.1 Zadanie 1

W modelu proporcjonalnych hazardów Coxa zakładamy że rozkład czasu do wystąpienia zdarzenia jednostki o charakterystyce z ma funkcję hazardu postaci :

$$h_z(t) = h_0(t)exp(\beta^T z),$$

gdzie h_0 jest bazową funkcją hazardu, o której niczego nie zakładamy, poza tym, że przyjmuje wartości nieujemne, zależy od czasu, ale nie zależy od charakterystyki z.

W tym zadaniu mamy oszacować parametry modelu, przyjmując za zmienną zależną zmienną `time`, a za charakterystyki zmienne: `age`, `sex`, `ph.ecog` i `ph.karno`. Najpierw, musimy z naszych danych usunąć wiersze z brakującymi obserwacjami, wycentrować zmienne ciągłe oraz wykonać one-hot encoding na zmiennych `sex` oraz `ph.ecog`.

```
library(survival)
data(lung)

zmienne <- c("time", "status", "age", "sex", "ph.ecog", "ph.karno")
dane <- lung[,zmienne]
dane <- na.omit(dane)
dane$age_c <- dane$age - mean(dane$age)
dane$ph.karno_c <- dane$ph.karno - mean(dane$ph.karno)
dane$sex <- as.factor(dane$sex)
dane$ph.ecog <- as.factor(dane$ph.ecog)

fit <- coxph(Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c, data =
 ↪  dane)
```

Oszacowane parametry naszego modelu są następujące :

```
##       age_c        sex2    ph.ecog1    ph.ecog2    ph.ecog3  ph.karno_c
##  0.01255988 -0.56567518  0.57805831  1.23989534  2.39585316  0.01242263
```

3.2 Zadanie 2

Interpretacja współczynników modelu z zadania 1 :

- Dla zmiennej `age_c` otrzymaliśmy współczynnik $\beta = 0.0126$, co daje nam ryzyko względne równe $\exp(\beta) = 1.0126$, czyli wzrost wieku o jeden rok wiąże się ze wzrostem ryzyka zgonu o około $1,3\%$.
- Dla zmiennej `sex2` dostaliśmy wartość parametru ($\beta = -0.5657$), gdzie `2` przy nazwie zmiennej oznacza kobiety. Ryzyko względne wynoszące $\exp(\beta) = 0.568$ i ujemna wartość współczynnika, mówi że płeć żeńska ma ryzyko zgonu o $43,2\%$ niższe nić płeć męska.
- Dla zmiennej `ph.ecog` otrzymaliśmy 3 różne wartości wspołczynników. Dla pacjentów z `ph.ecog = 1`, gdzie $\beta = 0.5781$ ryzyko zgonu jest wyższe o blisko 78% w porównaniu z pacjentami w pełni sprawnymi (`ph.ecog = 0`). Dla pacjentów z `ph.ecog = 2`, gdzie $\beta = 1.2399$, ryzyko rośnie około $3,46$ razy, natomiast dla pacjentów z `ph.ecog = 3`, gdzie $\beta = 2.3959$ ryzyko jest prawie 11 razy wyższe. Wyniki te wskazują na duże znaczenie tej zmiennej, przy predykcjach naszego modelu.
- Dla zmiennej `ph.karno_c` otrzymaliśmy $\beta = 0.0124$, czyli ryzyko względne wynosi $exp(\beta) = 1.0125$. Wskazuje to na wzrost ryzyka o około $1,2\%$ przy wzroście punktacji o 1 w skali Karnofsky'ego.

3.3 Zadanie 3

W tym zadaniu mamy wyznaczyć oszacowanie bazowej skumulowanej funkcji hazardu i bazowej funkcji przeżycia odpowiadającej rozkładowi czasu życia. Pierwsza z nich, czyli tzw. Estymator Breslowa, jest postaci:

$$\hat{H}_0(t) = \sum_{\tau_i \leq t} \frac{1}{\sum_{j \in R(\tau_i)} \exp(\hat{\beta}^T z_j)}$$

Stąd, za estymator bazowej funkcji przeżycia, możemy przyjąć :

$$\hat{S}_0(t) = exp[-\hat{H}_0(t)],$$

gdzie $\hat{H}_0(t)$ jest estymatorem Breslowa bazowej skumulowanej funkcji hazardu, do oszacowania którego wykorzystujemy funkcję `basehaz` z biblioteki `survival`.

```
bh <- basehaz(fit, centered = FALSE)
S0 <- exp(-bh$hazard)
```

3.4 Zadanie 4

W tym zadaniu mamy wyznaczyć oszacowanie skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia :

a) kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90 oraz

b) kobiety w wieku 70 lat o charakterystyce ph.ecog=2 i ph.karno=90

```
beta <- fit$coefficients
z_a <- c(70 - mean(dane$age), 1, 1, 0, 0, 90 - mean(dane$ph.karno))
z_b <- c(70 - mean(dane$age), 1, 0, 1, 0, 90 - mean(dane$ph.karno))

Hz_a <- bh$hazard * exp(sum(beta*z_a))
Hz_b <- bh$hazard * exp(sum(beta*z_b))
```

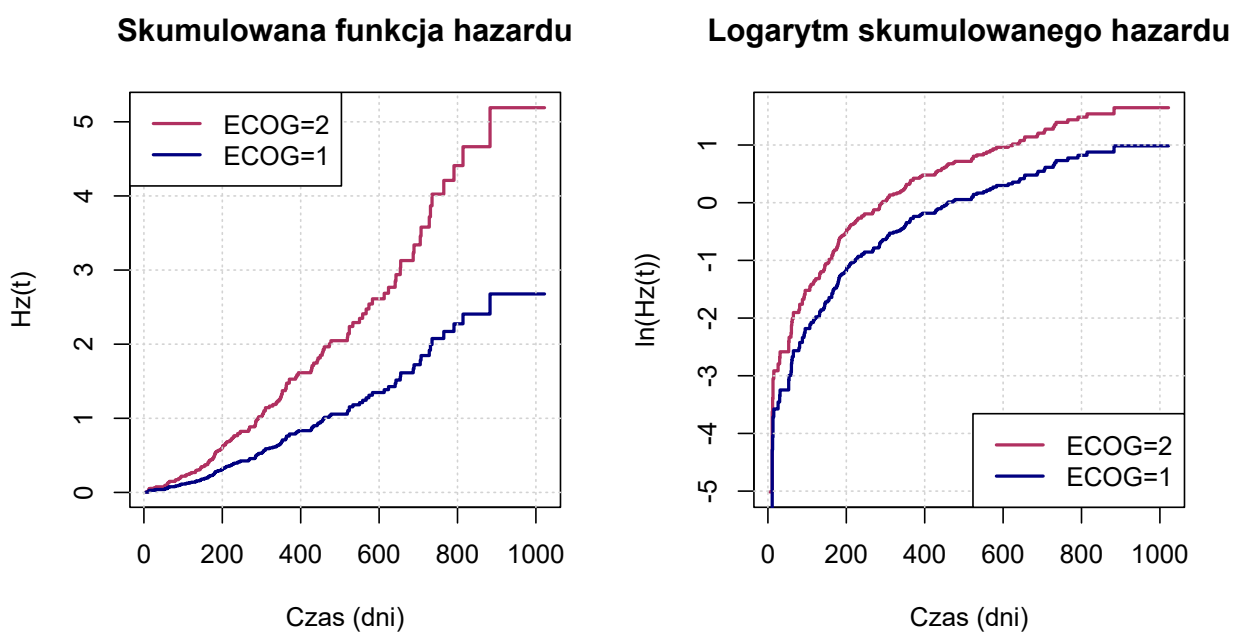

Rysunek 4: Porównanie skumulowanych funkcji hazardu i ich logarytmów dla dwóch pacjentek

Na wykresach logarytmu skumulowanej funkcji hazardu możemy zauważyć, że krzywe biegną względem siebie prawie równolegle, czyli logarytm ryzyka względnego równy $\beta^T(z_b - z_a)$ jest stały w czasie. Jest to zgodne z założeniami modelu proporcjonalnych hazardów Coxa, więc możemy założyć, że został on prawidłowo przyjęty.

3.5 Zadanie 5

W tym zadaniu mamy wyznaczyć oszacowanie funkcji przeżycia (w dniach) odpowiadającej rozkładowi czasu życia

(a) kobiety w wieku 70 lat o charakterystyce ph.ecog=1, ph.karno=90 oraz

(b) kobiety w wieku 70 lat o charakterystyce ph.ecog=2, ph.karno=90

i na podstawie tego oszacowania obliczyć szacowane prawdopodobieństwo, że czas życia kobiet o powyżej podanych charakterystykach będzie większy niż 300 dni.

```
S_a <- exp(-Hz_a)
S_b <- exp(-Hz_b)

prob_a <- S_a[max(which(bh$time <= 300))]
prob_b <- S_b[max(which(bh$time <= 300))]
```

Tabela 1: Porównanie wyników prawdopodobieństwa przeżycia P(T > 300) pacjentki z lepszą sprawnością (ECOG=1)

Zadanie	Wartość
Zadanie 3 (Model AFT)	0.5806085
Zadanie 8 (Model PH)	0.5806085
Zadanie 5 (Model PH Coxa)	0.5901344

Na podstawie powyższej tabeli możemy stwierdzić, że prawdopodobieństwa przeżycia są podobne, zarówno w modelach parametrycznych jak i semiparametrycznym Coxa, co wskazuje na to, iż rozkład Weibulla został poprawnie dobrany.

3.6 Zadanie 6

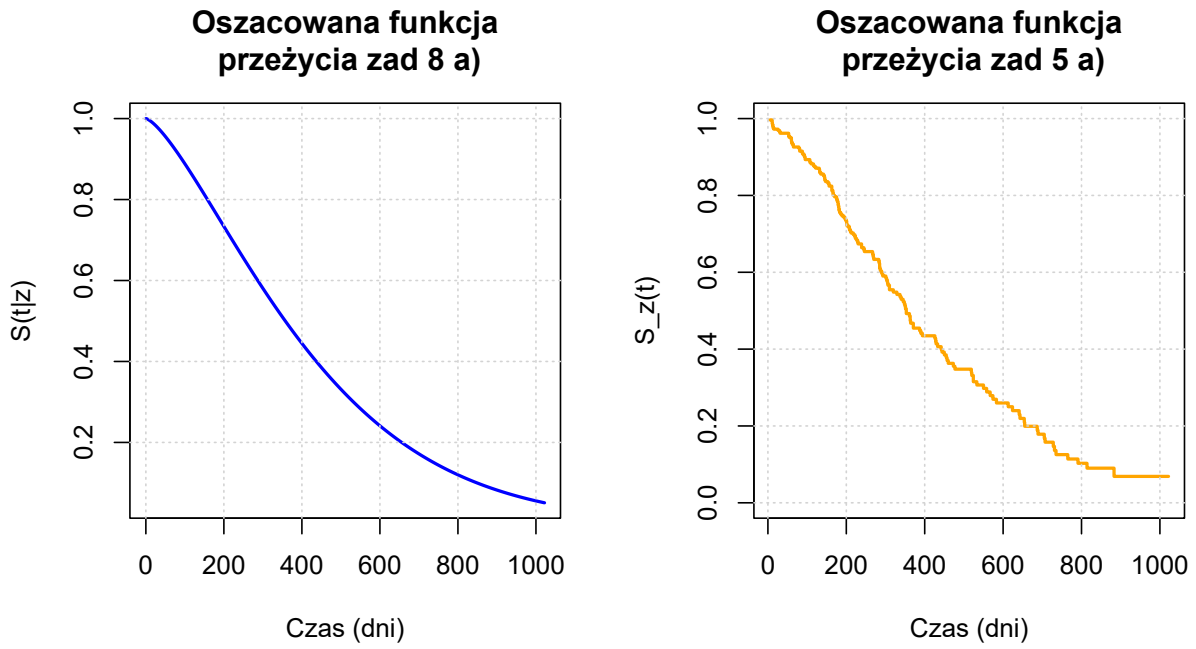

Rysunek 5: Porównanie oszacowanych na podstawie parametrów uzyskanych z modeli PH i proporcjonalnych hazardów Coxa funkcji przeżycia odpowiadających rozkładowi czasu życia pacjentki

Na podstawie powyższych wykresów możemy stwierdzić, że semiparametryczny model PH Coxa dobrze odwzorowuje strukturę danych, zbliżając się do wyników modelu parametrycznego. Krzywe przebiegają w niemal identyczny sposób, mimo schodkowej struktury funkcji przeżycia w przypadku Estymatora Breslowa.

4 Lista 11

4.1 Zadanie 1

Celem tego zadania jest oszacowanie parametrów modelu proporcjonalnych szans. Zgodnie z definicją, szansa jednostki o charakterystyce z w chwili t jest postaci:

$$\theta_z(t) = \theta_0(t)\exp(\beta^T z)$$

gdzie $\theta_0(t) = \frac{1-S_0(t)}{S_0(t)}$, S_0 jest bazową funkcją przeżycia. W naszym przypadku do oszacowania wykorzystana zostanie funkcja `prop.odds` z biblioteki `timereg` , która opiera się na modelu zdefiniowanym wzorem:

$$\ln\theta_z(t) = \ln\theta_0(t) + \beta^T z$$

Gdy za zmienna zależną przyjmiemy zmienną *time* a za charakterystyki zmienne: *age*, *sex*, *ph.ecog*, *ph.karno*, model będzie zakładał zależność:

$$\ln\theta_z(t) = \ln\theta_0(t) + \beta_{age}\text{age} + \beta_{sex}\text{sex} + \beta_{ph.ecog}\text{ph.ecog} + \beta_{ph.karno}\text{ph.karno}$$

```r
library(timereg)

set.seed(123)
model_ps <- prop.odds(Event(time, status==2) ~ age_centered + sex + ph.ecog +
 ↪  ph.karno_centered, data = lung_1, n.sim = 1000)
```

Wyniki estymacji parametrów modelu są następujące:

```
##                       estimate
## age_centered       0.013203683
## sex2              -0.953531370
## ph.ecog1           0.546984477
## ph.ecog2           1.446614150
## ph.ecog3           1.924513561
## ph.karno_centered -0.003698226
```

4.2 Zadanie 2

Zgodnie z przyjętą definicją modelu $\ln \theta_z(t) = \ln \theta_0(t) + \beta^T z$, dodatnia wartość współczynnika β oznacza zwiększenie szansy na wystąpienie zgonu (skrócenie czasu przeżycia), natomiast wartość ujemna oznacza zmniejszenie tej szansy.

- $\beta_{age} = 0.013$ sygnalizuje, że jednostka starsza ma w każdej chwili większe prawdopodobieństwo wystąpienia zgonu przed tą chwilą niż jednostka młodsza.
- $\beta_{sex} = -0.954$ oznacza, że bycie kobietą istotnie zmniejsza szansę na wystąpienie zgonu przed chwilą względem mężczyzn.
- $\beta_{ph.ecog1} = 0.547$, $\beta_{ph.ecog2} = 1.447$, $\beta_{ph.ecog3} = 1.925$ oznaczają, że im wyższa wartość współczynnika *ph.ecog*, tym większa jest szansa na wcześniejsze wystąpienie zgonu.
- $\beta_{ph.karno} = -0.004$ wskazuje na to, że jednostka z wyższym wynikiem punktowym posiada mniejsze prawdopodobieństwo wystąpienia zgonu niż jednostka o niższym wyniku.

4.3 Zadanie 3

Celem tego zadania jest wyznaczenie oszacowania bazowej skumulowanej funkcji hazardu i bazowej funkcji przeżycia odpowiadającej rozkładowi czasu życia, przyjmując model proporcjonalnych szans. W tym modelu funkcja przeżycia zadana jest wzorem:

$$S_z(t) = \frac{1}{1 + \theta_0(t) \exp(\beta^T z)}$$

A bazowa funkcja przeżycia oraz bazowa skumulowana funkcja hazardu są postaci odpowiednio: $S_0(t) = \frac{1}{1+\theta_0(t)}$, $H_0(t) = -\ln(S_0(t))$.

Na podstawie powyższych wzorów zaimplementowane zostaną funkcje `estymator_bazowej_funkcji_przezycia_p` oraz `estymator_bazowej_skumulowanej_funkcji_hazardu_ps` szacujące odpowiednio bazową funkcję przeżycia i bazową skumulowaną funkcję hazardu.

```
theta_0 <- model_ps$cum[,2]
estymator_bazowej_funkcji_przezycia_ps <- 1/(1+theta_0)
estymator_bazowej_skumulowanej_funkcji_hazardu_ps <-
 ↪  -log(estymator_bazowej_funkcji_przezycia_ps)
```

4.4 Zadanie 4

W tym zadaniu należy oszacować i porównać funkcje hazardu i logarytmy tych funkcji dla dwóch pacjentek o pewnych charakterystykach, przyjmując model proporcjonalnych szans.

Do wyznaczenia oszacowania skumulowanej funkcji hazardu wykorzystamy wzór:

$$H_z(t) = -\ln(S_z(t)) = \ln(1 + \theta_0(t)\exp(\beta^T z))$$

.

```
theta_0 <- model_ps$cum[,2]
przedzial_t <- model_ps$cum[,1]

beta_z_a <- model_ps$gamma["age_centered",]*age_centered_1 +
 ↪  model_ps$gamma["sex2",] +
 ↪  model_ps$gamma["ph.karno_centered",]*ph.karno_centered_1 +
 ↪  model_ps$gamma["ph.ecog1",]

beta_z_b <- model_ps$gamma["age_centered",]*age_centered_1 +
 ↪  model_ps$gamma["sex2",] +
 ↪  model_ps$gamma["ph.karno_centered",]*ph.karno_centered_1 +
 ↪  model_ps$gamma["ph.ecog2",]

estymator_funkcji_hazardu_pacjentek_ps <- function(beta_z){
  log(1+theta_0*exp(beta_z))
}
szacowany_hazard_pacjentka_a_ps <-
 ↪  estymator_funkcji_hazardu_pacjentek_ps(beta_z_a)
szacowany_hazard_pacjentka_b_ps <-
 ↪  estymator_funkcji_hazardu_pacjentek_ps(beta_z_b)
```

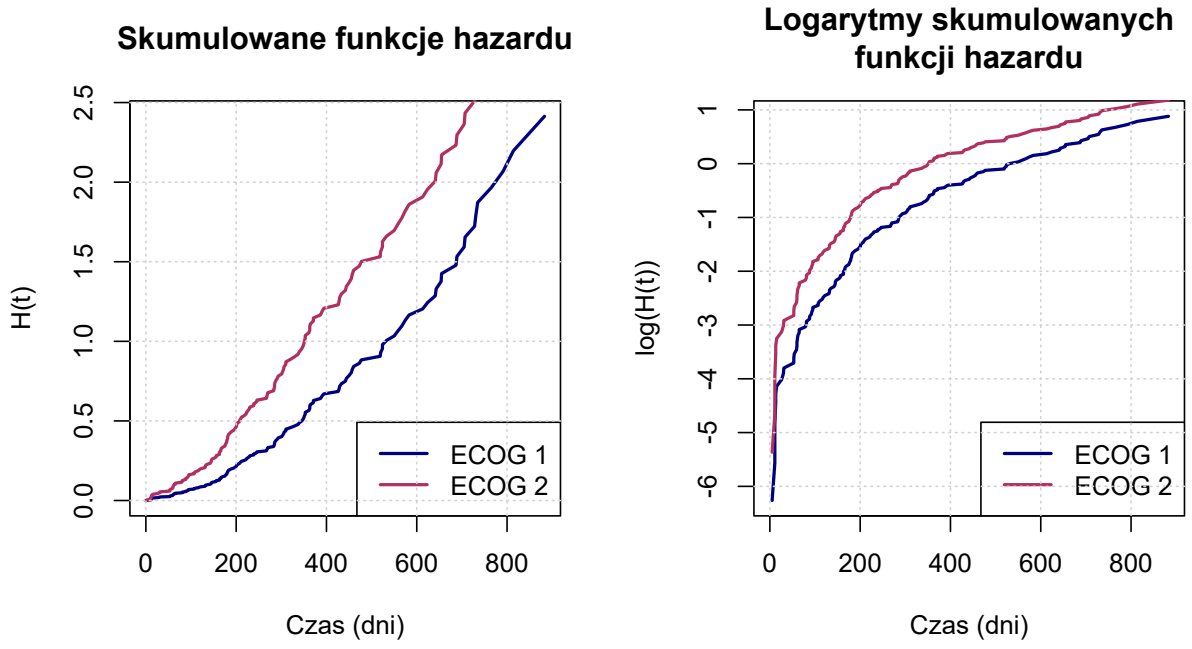

Rysunek 6: Porównanie skumulowanych funkcji hazardu i ich logarytmów dla dwóch pacjentek

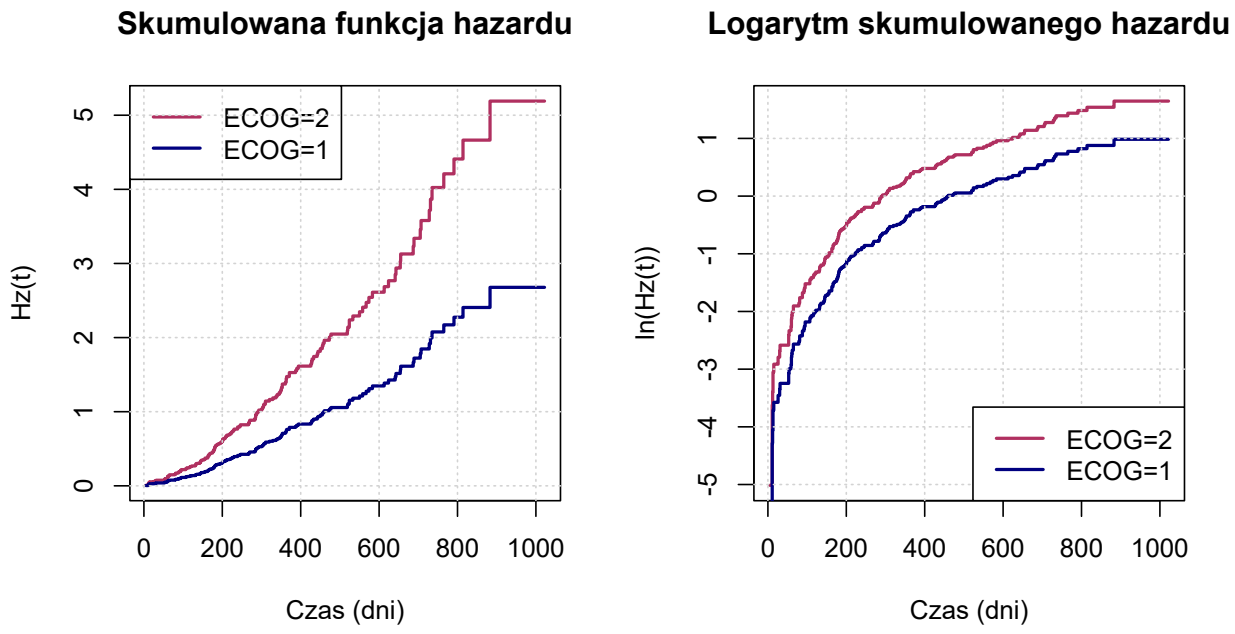

Na podstawie wykresów uzyskanych przyjmując model proporcjonalnych szans widać, że wyższe skumulowane ryzyko zgonu wykazuje pacjentka w gorszym stanie sprawności, natomiast wykresy logarytmów skumulowanego hazardu nie są wobec siebie równoległe. Dzieje się tak ponieważ w modelu proporcjonalnych szans stała w czasie różnica występuje dla logarytmu szans, a nie dla logarytmu hazardu. W modelu proporcjonalnych hazardów Coxa natomiast logarytmy skumulo-

wanego hazardu są równoległe. W tym modelu widać również dużo większą różnice niż w modelu proporcjonalnych szans między wartościami hazardu dla pacjentki w gorszym stanie sprawności a tymi dla pacjentki w lepszym stanie sprawności.

4.5 Zadanie 5

W tym zadaniu należy przyjmując model proporcjonalnych szans oszacować funkcję przeżycia, która będzie odpowiadać rozkładowi czasu życia pacjentek o pewnych charakterystykach, a następnie na podstawie uzyskanego oszacowania obliczyć szacowane prawdopodobieństwo, że czas życia tych kobiet będzie większy niż 300 dni.

Do tego zadania wykorzystamy fakt, że w tym modelu funkcja przeżycia zadana jest wzorem:

$$S_z(t) = \frac{1}{1 + \theta_0(t)\exp(\beta^T z)}$$

```
estymator_funkcji_przezycia_pacjentek_ps <- function(beta_z){
  1/(1+theta_0*exp(beta_z))
}
szacowana_funkcja_przezycia_pacjentka_a_ps <-
 ↪  estymator_funkcji_przezycia_pacjentek_ps(beta_z_a)
szacowana_funkcja_przezycia_pacjentka_b_ps <-
 ↪  estymator_funkcji_przezycia_pacjentek_ps(beta_z_b)

prawdopodobienstwo_przezycia_pacjentka_a <-
 ↪  szacowana_funkcja_przezycia_pacjentka_a_ps[which.min(abs(przedzial_t - 300))]

prawdopodobienstwo_przezycia_pacjentka_b <-
 ↪  szacowana_funkcja_przezycia_pacjentka_b_ps[which.min(abs(przedzial_t - 300))]
```

Prawdopodobieństwo, że czas życia tych kobiet będzie większy niż 300 dni, wynosi w przypadku pierwszej pacjentki z lepszą sprawnością około 0.6692398, natomiast w przypadku drugiej pacjentki z gorszą sprawnością około 0.4514333.

Tabela 2: Porównanie wyników prawdopodobieństwa przeżycia P(T > 300) pacjentki z lepszą sprawnością (ECOG=1)

Zadanie	Wartość
Zadanie 3 (Model AFT)	0.5806085
Zadanie 8 (Model PH)	0.5806085
Zadanie 5 (Model PH Coxa)	0.5901344
Zadanie 5 (Model PO)	0.6692398

Na podstawie tabeli widać wyraźnie wyższą wartość prawdopodobieństwa w modelu proporcjonalnych szans co sugeruje, że odmienne założenia matematyczne tego modelu inaczej szacują ryzyko.

4.6 Zadanie 6

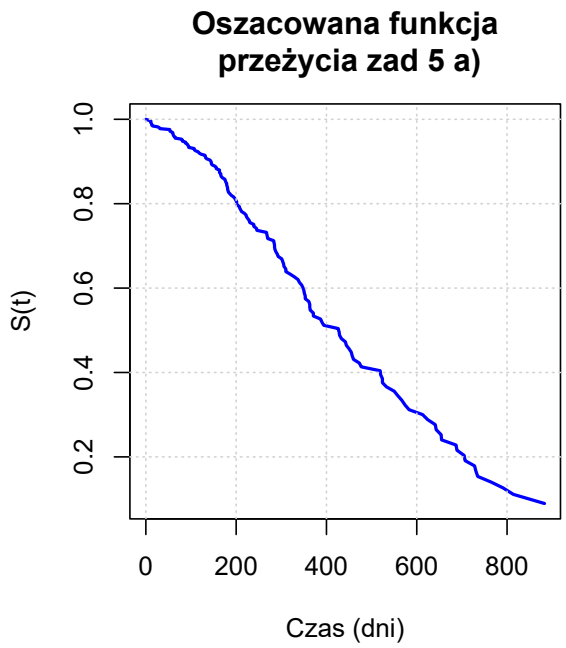

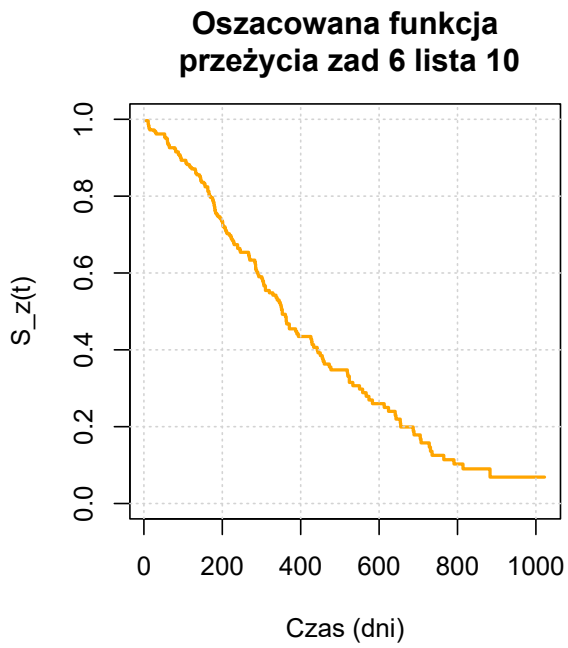

Na podstawie powyższych wykresów widać, że model proporcjonalnych szans przewiduje nieco wolniejszy spadek funkcji przeżycia w czasie niż model proporcjonalnych hazardów Coxa. Wynika to z różnych założeń matematycznych tych modeli.

5 Lista 12

5.1 Zadanie 1

W tym zadaniu przyjmując model przyspieszonego czasu awarii, w którym bazowa funkcja przeżycia odpowiada rozkładowi Weibulla, mamy zweryfikować hipotezę, że

a) zmienna `age` nie jest istotna w przyjętym modelu.

b) zmienna `sex` nie jest istotna w przyjętym modelu

c) rozkład czasu życia jest taki sam dla pacjenta o sprawności ECOG wg. lekarza na poziomie 0, 1, 2, 3

Skorzystamy w tym celu z **testu Walda**, w którym statystyka testowa jest postaci

$$Z = \frac{\hat{\vartheta} - \vartheta_0}{\sqrt{I^{-1}(\hat{\vartheta})}},$$

gdzie $\hat{\vartheta}$ jest estymatorem największej wiarogodnści nieznanego parametru ϑ, ϑ_0 jest hipotetycznym parametrem, $I^{-1}(\hat{\vartheta})$ jest oszacowaniem asymptotycznej wariancji estymatora $\hat{\vartheta}$.

Wartość poziomu krytycznego (p-value) w tym teście wyznaczana jest ze wzoru $p = 2(1 - \Phi(|z|)$, gdzie Φ jest dystrubuaną standardowego rozkładu normalnego, natomiast z – wartością statystyki Walda.

Będziemy również posługiwać się **testem opartym na ilorazie wiarygodności (IW)**, w którym statystykę testową możemy przedstawić w postaci

$$\lambda(x) = \frac{L(M_1)}{L(M_2)},$$

gdzie $L()$ jest maksimum wiarogodności, a M_1 i M_2 są pewnymi modelami, z tym, że model M_1 jest podmodelem modelu M_2, czyli takim modelem, w którym nie występują niektóre zmienne objaśniające, które występują w modelu M_2 lub w podmodelu M_1 między parametrami modelu zachodzi pewna relacja, np. $\beta_1 = \beta_2$, której nie zakładamy w modelu M_2.

Jeżeli chcemy zweryfikować hipotezę H_0, że model M_1 jest dobrze dopasowany do danych, przy hipotezie alternatywnej, że model M_2 jest istotnie lepiej dopasowany do danych, statystyka jest postaci

$$-2ln\lambda(X) = -2[ln(L(M_1)) - ln(L(M_2))].$$

```r
model1 <- survreg(Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c, data
 ↪  = dane, dist = "weibull")
model1_bez_age <- survreg(Surv(time, status) ~ sex + ph.ecog + ph.karno_c, data
 ↪  = dane, dist = "weibull")
model1_bez_sex <- survreg(Surv(time, status) ~ age_c + ph.ecog + ph.karno_c, data
 ↪  = dane, dist = "weibull")
model1_bez_ecog <- survreg(Surv(time, status) ~ age_c + sex + ph.karno_c, data =
 ↪  dane, dist = "weibull")

p_age_iw <- anova(model1_bez_age,model1)$`Pr(>Chi)`[2]
p_sex_iw <- anova(model1_bez_sex,model1)$`Pr(>Chi)`[2]
p_ecog_iw <- anova(model1_bez_ecog,model1)$`Pr(>Chi)`[2]

summary(model1)
```

```
##
## Call:
## survreg(formula = Surv(time, status) ~ age_c + sex + ph.ecog +
##     ph.karno_c, data = dane, dist = "weibull")
##                Value Std. Error     z       p
## (Intercept)  6.30118    0.14758 42.70 < 2e-16
## age_c       -0.00860    0.00679 -1.27 0.20530
## sex2         0.40828    0.12303  3.32 0.00091
## ph.ecog1    -0.42156    0.16762 -2.51 0.01191
## ph.ecog2    -0.92611    0.25142 -3.68 0.00023
## ph.ecog3    -1.68724    0.76728 -2.20 0.02788
## ph.karno_c  -0.01006    0.00678 -1.48 0.13792
## Log(scale)  -0.32760    0.06227 -5.26 1.4e-07
##
## Scale= 0.721
##
## Weibull distribution
## Loglik(model)= -1125.3   Loglik(intercept only)= -1141.1
##  Chisq= 31.52 on 6 degrees of freedom, p= 2e-05
## Number of Newton-Raphson Iterations: 5
## n= 226
```

Z powyższego podsumowania wynika, że korzystając z testu Walda, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna `age` nie jest istotna statystycznie. Wartość p wyniosła 0.2053. Analogiczny wniosek otrzymano, korzytając z testu IW, na poziomie istotności 0.05, gdzie p-value było równe 0.2014.

Możemy jednak stwierdzić, iż korzystając z testu Walda, na poziomie istotności 0.05, odrzucamy hipotezę, że zmienna `sex` nie jest istotna statystycznie (p-value $= 9.05 \times 10^{-4}$). Taki sam wniosek płynie z testu ilorazu wiarygodności, gdzie p-value wyniosło 5.96×10^{-4}.

Wartość p równa 0.0021, w teście ilorazu wiarygodności, pozwala nam odrzucić hipotezę, że rozkład czasu życia jest taki sam dla wszystkich poziomów sprawności ECOG (0,1,2,3).

5.2 Zadanie 2

W tym zadaniu, mamy do weryfikacji trzy takie same hipotezy jak w zadaniu 1, jednak będziemy bazować na modelu proporcjonalnych hazardów Coxa.

```
model2 <- coxph(Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c, data =
 ↪  dane)
model2_bez_age <- coxph(Surv(time, status) ~ sex + ph.ecog + ph.karno_c, data =
 ↪  dane)
model2_bez_sex <- coxph(Surv(time, status) ~ age_c + ph.ecog + ph.karno_c, data
 ↪  = dane)
model2_bez_ecog <- coxph(Surv(time, status) ~ age_c + sex + ph.karno_c, data =
 ↪  dane)

p_age_iw_cox <- anova(model2_bez_age,model2)$`Pr(>|Chi|)`[2]
p_sex_iw_cox <- anova(model2_bez_sex,model2)$`Pr(>|Chi|)`[2]
p_ecog_iw_cox <- anova(model2_bez_ecog,model2)$`Pr(>|Chi|)`[2]

summary(model2)
```

```
## Call:
## coxph(formula = Surv(time, status) ~ age_c + sex + ph.ecog +
##     ph.karno_c, data = dane)
##
##   n= 226, number of events= 163
##
##                 coef exp(coef)  se(coef)      z Pr(>|z|)
## age_c       0.012560  1.012639  0.009452  1.329 0.183903
## sex2       -0.565675  0.567977  0.169750 -3.332 0.000861 ***
## ph.ecog1    0.578058  1.782574  0.236399  2.445 0.014474 *
## ph.ecog2    1.239895  3.455252  0.355303  3.490 0.000484 ***
## ph.ecog3    2.395853 10.977560  1.081217  2.216 0.026699 *
## ph.karno_c  0.012423  1.012500  0.009588  1.296 0.195118
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
##            exp(coef) exp(-coef) lower .95 upper .95
## age_c          1.013    0.98752    0.9941    1.0316
## sex2           0.568    1.76064    0.4072    0.7922
## ph.ecog1       1.783    0.56099    1.1216    2.8332
## ph.ecog2       3.455    0.28941    1.7220    6.9329
## ph.ecog3      10.978    0.09109    1.3188   91.3775
## ph.karno_c     1.013    0.98765    0.9936    1.0317
##
## Concordance= 0.633  (se = 0.025 )
## Likelihood ratio test= 31.58  on 6 df,   p=2e-05
## Wald test            = 32.04  on 6 df,   p=2e-05
## Score (logrank) test = 34.14  on 6 df,   p=6e-06
```

Z powyższego podsumowania wynika, że korzystając z testu Walda, na poziomie istotności 0.05, nie mamy podstaw do odrzucenia hipotezy, że zmienna `age` nie jest istotna statystycznie. Wartość p wyniosła 0.1839. Analogiczny wniosek otrzymano, korzytając z testu IW, na poziomie istotności 0.05, gdzie p-value było równe 0.1804.

Stwierdzamy jednak, iż korzystając z testu Walda, na poziomie istotności 0.05, odrzucamy hipotezę, że zmienna `sex` nie jest istotna statystycznie (p-value $= 8.61 \times 10^{-4}$). Taki sam wniosek płynie z testu ilorazu wiarygodności IW, gdzie p-value wyniosło 6.29×10^{-4}.

Wartość poziomu krytycznego równa 0.0036, w teście ilorazu wiarygodności, pozwala nam odrzucić hipotezę, że rozkład czasu życia jest taki sam dla wszystkich poziomów sprawności ECOG (0,1,2,3).